

## **Classificação de Manganês e Cobre na Folha da Mexerica, Orientado por Redes Neurais**

## **Classification of Manganese and Copper in Tangerine Leaves, Guided by Neural Networks**

Fagundes. L    { lucas.fagundes3@fatec.sp.gov.br }  
Freitas. A    { amanda.freitas14@fatec.sp.gov.br }  
Freitas. V    { valeria.freitas@fatec.sp.gov.br }  
Medina. L    { luiz.medina@fatec.sp.gov.br }

### **RESUMO**

Este trabalho apresenta o desenvolvimento inicial do projeto NitrusLeaf, que utiliza técnicas de Inteligência Artificial (IA) para identificar deficiências nutricionais de cobre e manganês nas folhas da citrus reticulata (mexerica), alinhando-se com o Objetivo de Desenvolvimento Sustentável (ODS) 2 - Fome zero e agricultura sustentável da Agenda 2030 da ONU. O objetivo é reduzir as perdas na produção agrícola e promover a sustentabilidade. A aplicação visa facilitar aos agricultores a identificação desses problemas de forma rápida e precisa, utilizando visão computacional para analisar imagens das folhas, capturadas por drones ou enviadas pelos agricultores. A IA será treinada com o uso de redes neurais convolucionais (CNNs) utilizando um banco de dados de imagens de folhas com e sem deficiências. Espera-se que o NitrusLeaf se torne uma ferramenta eficaz para a agricultura sustentável após a conclusão desta pesquisa.

**PALAVRAS-CHAVE:** Citrus reticulata; Deficiência nutricional; Visão computacional; Manganês; Cobre.

### **ABSTRACT**

This work presents the initial development of the NitrusLeaf project, which utilizes specific Artificial Intelligence (AI) techniques to identify copper and manganese nutritional deficiencies in citrus reticulata (tangerine) leaves, with the aim of following the UN's 2030 Agenda, specifically Sustainable Development Goal (SDG) 2 Zero Hunger and Sustainable Agriculture, seeking to reduce agricultural production losses and promote sustainability. This application aims to help farmers identify these problems more easily and quickly, reducing tangerine crop losses and increasing plant health. Through computer vision, the system analyzes images of leaves, taken by drones or sent by farmers, and provides an accurate diagnosis. Convolutional Neural Networks (CNNs) will be used to train the AI with a database of images of leaves with and without deficiencies. After further research, it is expected that NitrusLeaf will become an effective tool for sustainable agriculture.

**KEYWORDS:** Citrus reticulata; Nutritional deficiency; Computer Vision; Manganese; Copper.

## **INTRODUÇÃO**

Vivemos em um mundo onde a comida não é suficiente para todos, e problemas como guerras e pobreza continuam a assolar diversas regiões. Esse mal perdura há muito tempo, e, em 1945, a Organização das Nações Unidas (ONU) foi criada para tentar combater esses desafios globais. Como parte dos esforços para enfrentar essas questões, a ONU lançou, em setembro de 2015, os Objetivos de Desenvolvimento Sustentável (ODS), definidos na Agenda 2030. Esse movimento global tem como metas principais erradicar a pobreza, proteger o meio ambiente e o clima, acabar com a fome e promover paz e prosperidade em todo o mundo. No presente projeto, buscamos reduzir as possíveis perdas de Citrus reticulata (mexerica), o que se alinha ao ODS 2 — Fome Zero e Agricultura Sustentável. Nosso foco é garantir uma maior produtividade das mexericas, contribuindo assim para a segurança alimentar e a sustentabilidade agrícola.(Fundecitrus, 2018).

Atualmente, a produção de citros está em declínio em todo o mundo, devido a condições climáticas adversas, além de pragas e doenças que afetam essas culturas. Algumas dessas doenças têm alcance global, como Phytophthora citrophthora, Xylella fastidiosa, o cancro cítrico e o greening,

também conhecido como HLB (Huanglongbing). Nas Américas do Sul e do Norte, há uma alta incidência do greening. Nos Estados Unidos, por exemplo, a colheita do último ano foi menor do que o esperado, resultado da combinação de infestações por greening e furacões (Aregbe; Farnsworth; Simnitt, 2024).

No Brasil, a taxa de infecção por greening também é significativa. Essa doença ataca todas as variedades de citros e, uma vez infectada, a planta não tem cura. Plantas jovens contaminadas geralmente não chegam a produzir frutos, enquanto plantas adultas sofrem queda prematura de frutos e, eventualmente, definhamento. Uma das principais bactérias causadoras do greening no Brasil é a *Candidatus Liberibacter asiaticus*, responsável por 99% dos casos registrados no país. A bactéria é transmitida pelo psílídeo *Diaphorina citri*, também conhecido como psílídeo-asiático-dos-citros, um inseto de coloração branco-acinzentada com manchas escuras nas asas, que mede entre 2 e 3 mm. Esse inseto é especialmente frequente nos pomares durante as épocas de brotação das plantas. O estado de São Paulo é uma das regiões mais afetadas pelo greening, conforme evidenciado pelo Programa Nacional de Prevenção e Controle ao HLB (PNCHLB), que exige a eliminação de plantas com menos de oito anos contaminadas pelo HLB, o que inclui áreas como o Vale do Ribeira, também no estado de São Paulo (Fundecitrus, 2018).

O HLB, popularmente conhecido como greening, teve origem na Ásia há mais de 100 anos. No Brasil, a doença foi identificada em 2004, nas regiões Centro e Leste do Estado de São Paulo, e desde então se espalhou para todas as áreas citrícolas do estado, bem como para pomares em Minas Gerais e Paraná. Além disso, a doença se expandiu para outros países da América do Sul, como Argentina e Paraguai (Fundecitrus, 2018).

Como o greening é uma doença incurável, a remoção imediata das plantas infectadas é necessária após a detecção em um campo, a fim de reduzir o risco de contaminação para as plantas ao redor. Infelizmente, pouco pode ser feito para salvar plantas infectadas. Os sintomas do greening incluem folhas amareladas quando jovens, mosqueadas com pintas ou malhas escuras quando maduras. Além disso, as folhas afetadas tendem a cair, sendo substituídas por outras em posição vertical. Por isso, a distinção entre o greening e outras doenças ou condições com sintomas semelhantes é crucial, para evitar a eliminação de plantas que poderiam ser salvas. Duas das condições causadas por deficiência de nutrientes que apresentam semelhança com os sintomas do greening são a deficiência de cobre e a de manganês. A deficiência de cobre manifesta-se por folhas pequenas e deformadas no novo ciclo de crescimento, com nervuras verdes bem definidas sobre uma coloração mais clara. As plantas também podem apresentar folhas maiores que o normal, além de bolsas de goma nos ramos novos e na casca dos frutos. Já a deficiência de manganês se caracteriza por folhas novas de tamanho quase normal, perda de brilho e clorose — uma tonalidade amarelada entre as nervuras, que permanecem verdes (Fundecitrus, 2018; Bueno; Gasparotto, 1999).

Nosso projeto tem como objetivo analisar as deficiências de cobre e manganês nas folhas de *Citrus reticulata*. Essas duas condições foram selecionadas por apresentarem semelhanças com alguns dos sintomas do greening, como o amarelamento e o crescimento anormal das folhas. Utilizando a análise de imagens, buscamos identificar se uma folha apresenta sinais de uma dessas deficiências nutricionais. Com base no diagnóstico, o agricultor poderá adotar as medidas corretivas adequadas, como a verificação do estado nutricional do solo e a aplicação de fertilizantes de forma precisa e equilibrada, contribuindo para a saúde da planta e a maximização da produtividade.

Atualmente, a Inteligência Artificial (IA) é utilizada em diversas áreas do mercado de trabalho, desde o setor de saúde até os anúncios que vemos diariamente. Ela tem sido aplicada para aumentar a eficiência e a qualidade, proporcionando resultados mais precisos em uma ampla gama de situações. O objetivo da IA é operar de forma autônoma, oferecendo respostas exatas para cada contexto, sem

a necessidade de intervenção humana. Assim, a adoção da IA em grandes empresas, hospitais e em outros setores que buscam automação está se tornando cada vez mais comum e significativa.

O sistema desenvolvido será um aplicativo móvel que utilizará Inteligência Artificial (IA) para identificar deficiências de manganês e cobre nas folhas de mexerica. Com essa ferramenta, o usuário poderá apontar a câmera do celular para a folha, permitindo que a IA analise possíveis sinais de deficiência, como clorose ou uma coloração verde intensa. Com base nessa análise, o sistema indicará se a folha apresenta sintomas de deficiência nutricional ou se está saudável, proporcionando um diagnóstico prático e acessível diretamente no campo.

A parte da Inteligência Artificial (IA) que nosso projeto utilizará será a visão computacional, que permite que a máquina "veja" visualmente e identifique diversos dados a partir das imagens. Para aplicar a visão computacional, são necessárias duas tecnologias-chave: redes neurais convolucionais e aprendizado de máquina profundo, conhecido como Deep Learning. Essas ferramentas possibilitam que a máquina reconheça padrões específicos. A rede neural convolucional é utilizada em contextos que exigem visão computacional e é inspirada na organização hierárquica do córtex visual humano, sendo composta por camadas interconectadas de neurônios (Qin *et al.*, 2018). Por outro lado, o Deep Learning é uma evolução do aprendizado de máquina, consistindo em uma rede neural com múltiplas camadas. Com o Deep Learning, basta indicar se uma imagem contém uma folha de Citrus reticulata saudável ou com deficiência, e, ao fornecer muitas imagens rotuladas, a máquina aprenderá a identificar os padrões. Em contraste, no aprendizado de máquina tradicional, é necessário descrever de forma programática como é a folha saudável, especificando as características dos pixels na imagem do padrão que se deseja que a máquina reconheça (Christin; Hervet; Lecomte, 2019).

## OBJETIVO

A agricultura de citros enfrenta diversos tipos de doenças, que podem ser identificadas a partir da observação de deformidades físicas e alterações de pigmentação em suas folhas, cascas e frutos, além da presença de pragas que afetam a qualidade final do alimento. A análise foliar é uma técnica comum utilizada para diagnosticar deficiências nutricionais em plantas, que consiste na coleta de folhas seguida pela análise química para determinar a concentração de determinados nutrientes. No entanto, esse processo pode ser demorado e requer habilidades técnicas especializadas. A utilização de inteligência artificial (IA) para buscar padrões visuais pode facilitar a determinação desse diagnóstico.

O projeto tem como objetivo desenvolver um sistema capaz de reconhecer deficiências de manganês e cobre em folhas de mexerica a partir da análise de fotos de manchas, utilizando IA para facilitar um diagnóstico direto ao agricultor. Os objetivos principais são:

1. **Aprofundar na coleta de informações sobre os sintomas das deficiências nutricionais específicas da mexerica.**
2. **Desenvolver um banco de imagens com uma variedade de níveis de deficiência de manganês e cobre para análise do problema.**
3. **Realizar o treinamento da IA utilizando uma arquitetura de rede Neural Convolucional (CNNs).**
4. **Implementar um sistema que possibilite a identificação técnica das deficiências por meio de Inteligência Artificial, utilizando imagens digitais capturadas pelos próprios agricultores.**

Além dos objetivos principais, este projeto também busca atingir os seguintes objetivos específicos:

1. **Desenvolver um sistema de visão computacional para identificar sintomas de**

deficiências nutricionais em imagens de folhas de mexericas, permitindo uma análise detalhada e precisa das condições de saúde da planta.

2. **Criar uma funcionalidade que permita ao usuário analisar a folha da mexerica ao apontar a câmera do celular para a planta, possibilitando que a IA identifique e interprete o estado de saúde da planta em tempo real.**
3. **Após a análise do estado da planta, habilitar o cadastro do diagnóstico pelo usuário, com a opção de registrar o talhão e o número da planta para facilitar o acompanhamento e controle.**
4. **Implementar uma funcionalidade de histórico para monitoramento, permitindo que o usuário visualize a evolução do estado das plantas e dos talhões ao longo do tempo, com a possibilidade de comparar estados anteriores e atuais.**
5. **Desenvolver, se possível, uma funcionalidade para a captura de imagens da plantação por drones, possibilitando a identificação de áreas mais ou menos saudáveis, facilitando a detecção de plantas potencialmente doentes.**
6. **Incluir um mapa interativo que mostre a localização de cada planta nos talhões, com legendas que indiquem a situação de saúde, número da planta e do talhão.**
7. **Criar um mapa de calor para destacar áreas críticas, com cores representando diferentes situações, como deficiência de manganês, deficiência de cobre e outras deficiências, facilitando a visualização dos pontos de foco e concentração de problemas.**
8. **Realizar uma análise de precisão do sistema desenvolvido, comparando-o com os métodos tradicionais de análise de solo e folhas, para validar a eficácia do sistema.**
9. **Fornecer recomendações práticas e úteis com base nos resultados obtidos, para que os agricultores possam tratar de forma direcionada as deficiências detectadas, caso necessário.**

## **ESTADO DA ARTE**

Entre os muitos desafios enfrentados pelos agricultores, a deficiência de minerais nas plantas é uma preocupação significativa, pois pode resultar em perdas de produtividade e qualidade dos cultivos. A mexerica (*Citrus reticulata*) é uma das culturas suscetíveis a deficiências minerais, o que pode afetar seu crescimento, desenvolvimento e produção.

O artigo de Muthusamy e Ramu (2023) discute avanços recentes nas tecnologias de visão computacional, aprendizado de máquina (ML) e aprendizado profundo (DL), que têm sido aplicadas ao monitoramento agrícola para melhorar a produtividade e a qualidade das colheitas. Entre as tecnologias abordadas, destacam-se imagens de satélite, sensoriamento remoto, Internet das Coisas (IoT), dispositivos de sensor e Veículos Aéreos Não Tripulados (VANTs). Esses sistemas são utilizados para capturar dados visuais e detectar deficiências nutricionais em tempo real, permitindo um diagnóstico precoce e aumentando a eficiência na aplicação de insumos agrícolas.

O artigo cita trabalhos que demonstram como a visão computacional, combinada com ML e DL, pode identificar padrões visuais como coloração, textura e bordas em imagens de plantas. Esse exemplo ilustra como essas técnicas permitem um diagnóstico não invasivo, usando câmeras digitais e algoritmos avançados para diferenciar entre folhas saudáveis e folhas com deficiência nutricional.

Com base nesses avanços, é viável que o projeto NitrusLeaf implemente um sistema semelhante, utilizando smartphones e visão computacional para capturar e analisar imagens de folhas de mexerica. Com o suporte de algoritmos de ML/DL, o sistema pode processar essas imagens para identificar

deficiências específicas, como de cobre e manganês, diretamente no campo.

O artigo de (Ghorai *et al.*, 2021) explora um pipeline detalhado para identificar doenças e deficiências nutricionais em plantas, baseado em técnicas de processamento de imagem. Esse pipeline, ou sequência organizada de etapas, permite a análise automatizada e eficiente de imagens de plantas, produzindo diagnósticos agrícolas precisos. O pipeline descrito no artigo inclui as seguintes fases: Aquisição de imagem, Pré-processamento, Segmentação, Extração de características, Classificação e, finalmente, Detecção e Diagnóstico. Cada fase depende da anterior e contribui para refinar e analisar os dados, de modo a produzir uma resposta confiável sobre a condição da planta.

- **Aquisição de imagem:** Envolve a captura de imagens de plantas utilizando câmeras, UAVs (drones) ou dispositivos móveis. Essa etapa garante que a imagem tenha qualidade suficiente para as próximas fases do processamento.
- **Pré-processamento:** Aqui, técnicas de correção de ruído, ajuste de contraste e brilho, além de redimensionamento e rotação, são aplicadas para melhorar a qualidade da imagem e facilitar a segmentação.
- **Segmentação de imagem:** É feita para isolar a folha ou parte relevante da planta, separando-a do fundo. Técnicas comuns incluem limiarização, segmentação por cor e abordagens de aprendizado de máquina.
- **Extração de características:** Essa etapa analisa e extrai informações importantes, como cor, textura e forma, que são essenciais para diferenciar entre folhas saudáveis e afetadas. Métodos como histogramas de cor e a Matriz de Co-ocorrência de Níveis de Cinza (GLCM) são comumente usados.
- **Classificação:** Modelos de aprendizado de máquina ou redes neurais profundas (como CNNs e SVMs) são empregados para classificar as imagens, diferenciando as folhas saudáveis das que apresentam deficiências ou doenças.
- **Detecção e Diagnóstico:** A última etapa envolve o diagnóstico da condição da planta, onde é identificada a doença ou deficiência nutricional específica, e recomendações são geradas com base nos resultados da classificação.

Além disso, o artigo aborda técnicas não intrusivas para detecção de deficiências nutricionais, utilizando métodos avançados de verificação de imagem. Por exemplo, uma tabela mostra o uso do método RGB para identificar deficiências de nutrientes, incluindo a deficiência de manganês em citrus. Esse tipo de abordagem reforça a viabilidade do nosso projeto, NitrusLeaf, que busca identificar deficiências de cobre e manganês nas folhas de mexerica. Ao adotar essas tecnologias e adaptar o pipeline descrito, o NitrusLeaf poderá oferecer uma solução eficaz e prática para diagnósticos agrícolas baseados em visão computacional.

O artigo de Tran *et al.* (2019) utiliza os modelos Inception-ResNet v2, Autoencoder de Rede Neural Convolutiva (CNN), e uma combinação desses dois modelos por meio de Ensemble Averaging para melhorar a detecção precoce de deficiências nutricionais de cálcio, nitrogênio e potássio em plantações de tomate. A identificação rápida dessas deficiências é essencial, pois a falta de intervenção pode levar a condições mais graves, incluindo doenças que afetam a produtividade e a saúde das plantas. Para garantir que os modelos fossem treinados com imagens robustas e representativas, os autores aplicaram técnicas de pré-processamento e aumento de dados (data augmentation), como ajuste de ângulo, brilho e contraste. Essas técnicas aumentaram a diversidade visual do conjunto de dados, ajudando os modelos a generalizar melhor e a detectar padrões de deficiência com mais precisão.

A escolha dos modelos Inception-ResNet v2 e Autoencoder foi motivada pela capacidade dessas arquiteturas em capturar características visuais complexas nas folhas e nos frutos, essenciais

para distinguir entre deficiências nutricionais que compartilham sintomas visuais semelhantes. O Inception-ResNet v2, por exemplo, combina as vantagens das redes Inception e ResNet, permitindo uma análise detalhada de padrões locais e globais na imagem. Já o Autoencoder oferece uma estrutura de compressão e reconstrução útil para destacar anomalias visuais, como as causadas por deficiências. O estudo usou um conjunto de 571 imagens de tomates cultivados em estufas, das quais 80% (461 imagens) foram destinadas ao treinamento e 20% (110 imagens) para a validação dos modelos. Após extensivos testes, os resultados mostraram que o Inception-ResNet v2 obteve uma precisão de 87,27%, o Autoencoder alcançou 79,09%, e a técnica de Ensemble Averaging conseguiu uma precisão de 91%.

As abordagens e metodologias deste artigo são relevantes para nosso projeto, pois ambos compartilham o foco em visão computacional e aprendizado profundo para a detecção de deficiências nutricionais em plantas. Enquanto o artigo de Tran et al. se concentra em deficiências de nitrogênio e potássio em folhas de tomate, nosso projeto utiliza técnicas similares para identificar deficiências de cobre e manganês em folhas de mexerica. Assim, este trabalho oferece uma base metodológica útil, especialmente na escolha de modelos de CNN e na importância de uma abordagem de ensemble para melhorar a precisão no diagnóstico.

Esses resultados indicam que, com o uso apropriado das tecnologias discutidas, nosso projeto NitrusLeaf poderá alcançar resultados satisfatórios. Aproveitando as tecnologias descritas, buscamos oferecer uma funcionalidade avançada ao sistema, permitindo a identificação precisa de deficiências minerais, como as de manganês e cobre, por meio da análise de imagens capturadas pelos usuários.

## **METODOLOGIA**

### **1 METODOLOGIA**

O desenvolvimento do projeto será conduzido em etapas que seguem a metodologia de desenvolvimento ágil (Scrum), permitindo uma adaptação flexível aos requisitos ao longo do processo. As etapas principais incluem:

#### **1.1 COLETA DE REQUISITOS E DESIGN**

Usaremos o Figma para desenvolver protótipos de baixa e alta fidelidade das interfaces da aplicação, garantindo uma visualização clara dos requisitos funcionais e de usabilidade.

#### **1.2 DESENVOLVIMENTO FRONT-END**

O código será estruturado com HTML e CSS para a definição de layout e estilo, enquanto o JavaScript será utilizado para proporcionar interatividade. O *Node.js* será empregado para a criação de componentes reutilizáveis, melhorando a eficiência e a modularidade do código.

#### **1.3 DESENVOLVIMENTO BACK-END E BANCO DE DADOS**

O banco de dados será modelado no *brModelo* e implementado no *MySQL* para garantir a correta estruturação dos dados. A interação entre *front-end* e *back-end* será implementada usando *Python* para a integração da visão computacional e *Node.js* no computador, enquanto o *React Native* será utilizado para criar uma API no *mobile*, com foco na criação de uma API eficiente.

## 1.4 TESTES E VALIDAÇÃO

Após a implementação, serão realizados testes automatizados e manuais para validar o funcionamento correto de cada parte do sistema. Ferramentas como Selenium poderão ser utilizadas para automatizar os testes de interface.

## 1.5 PUBLICAÇÃO E ACOMPANHAMENTO

O sistema será implementado na plataforma Web, sendo feito com *front-end* e *back-end* primeiramente, e em uma versão futura, algumas das funções disponíveis na Web serão adaptadas para *mobile*, com o objetivo inicial de permitir o uso do aplicativo no campo para escanear a folha em tempo real e receber o feedback instantâneo. A fácil escalabilidade e manutenção serão garantidas, e ajustes serão feitos com base no feedback dos usuários após a implantação.

## RESULTADOS PRELIMINARES

Após aplicar os métodos descritos, foram alcançados os seguintes resultados: a criação do site do projeto, utilizando HTML, CSS, JavaScript e NODE.JS, a criação do Diagrama de Classe e Diagrama de Objeto, além do banco de dados físico (MBD).

### Prototipação do aplicativo no Figma

A Figura 1 mostra a tela de Landing Page do projeto, onde são exibidas as principais funcionalidades.



Fonte: Autoria Própria (2024)

A tela inicial Figura 2 oferece as opções de escanear uma folha com a câmera do celular



ou fazer o upload de uma imagem para análise. Abaixo dessas opções, há um gráfico de pizza que mostra a porcentagem das ocorrências totais: amarelo para manganês, laranja-avermelhado para cobre e cinza para “adversos” (casos sem deficiência de cobre ou manganês). No lado direito, um quadro exibe análises recentes, incluindo o número total de plantas analisadas, tratadas e plantadas. No canto esquerdo, um menu permite acesso a outras telas do aplicativo, como histórico, drone e configurações gerais.

Figura 2 – Tela Início



Fonte: Autoria Própria (2024)

Ao selecionar “escanear folha”, o usuário deverá apontar a câmera para a folha escolhida. Caso opte por fazer o upload de uma imagem, o aplicativo iniciará a análise e, ao concluir, abrirá a tela Figura 3 mostrando a probabilidade da deficiência identificada. O usuário deve selecionar a planta analisada, o talhão ao qual pertence e pode adicionar um relatório, se necessário, antes de finalizar.



Figura 3 – Cadastro Diagnóstico

The screenshot displays the 'Resultado' (Result) screen of the NitrusLeaf application. At the top, the NitrusLeaf logo is on the left and a user profile icon is on the right. A vertical orange sidebar on the left contains icons for home, list, add, settings, and back. The main content area has a title 'Resultado' and a large box for the diagnosis result. Inside this box, the text 'Probabilidade de ser Deficiência de Cobre' (Probability of being Copper Deficiency) is shown. To the right is a donut chart with 92% in red and 8% in grey. Below the title, there are input fields for 'Nome Talhão' (Plot Name) and 'Nome Pé' (Plant Name), each with an 'Editar' (Edit) button. The 'Nome Talhão' field contains 'Talhão 1' and the 'Nome Pé' field contains 'Pé 1'. Below these is a text input field labeled 'Adicionar relatório...' (Add report...) and a green 'Finalizar' (Finish) button. The footer contains the copyright '© 2024 NitrusLeaf' and the contact email 'Contato: contato@nitrusleaf.net'.

**Resultado**

Probabilidade de ser Deficiência de Cobre

92%

Deficiência de Cobre

Nome Talhão	Nome Pé	Editar
Talhão 1	Pé 1	
<input type="text" value="Adicionar relatório..."/>		
<button>Finalizar</button>		

© 2024 NitrusLeaf

Contato: contato@nitrusleaf.net

Fonte: Autoria Própria (2024)

Para verificar as plantas cadastradas no aplicativo, o usuário acessa a tela de histórico Figura 4. Nessa tela, é possível ver a quantidade de plantas cadastradas em cada talhão, selecionar a propriedade sendo verificada, bem como visualizar o número de plantas analisadas até o momento. No lado direito, uma janela exibe o total de talhões e plantas registrados, além do número de plantas analisadas e diagnosticadas.

Figura 4 – Tela Relatórios

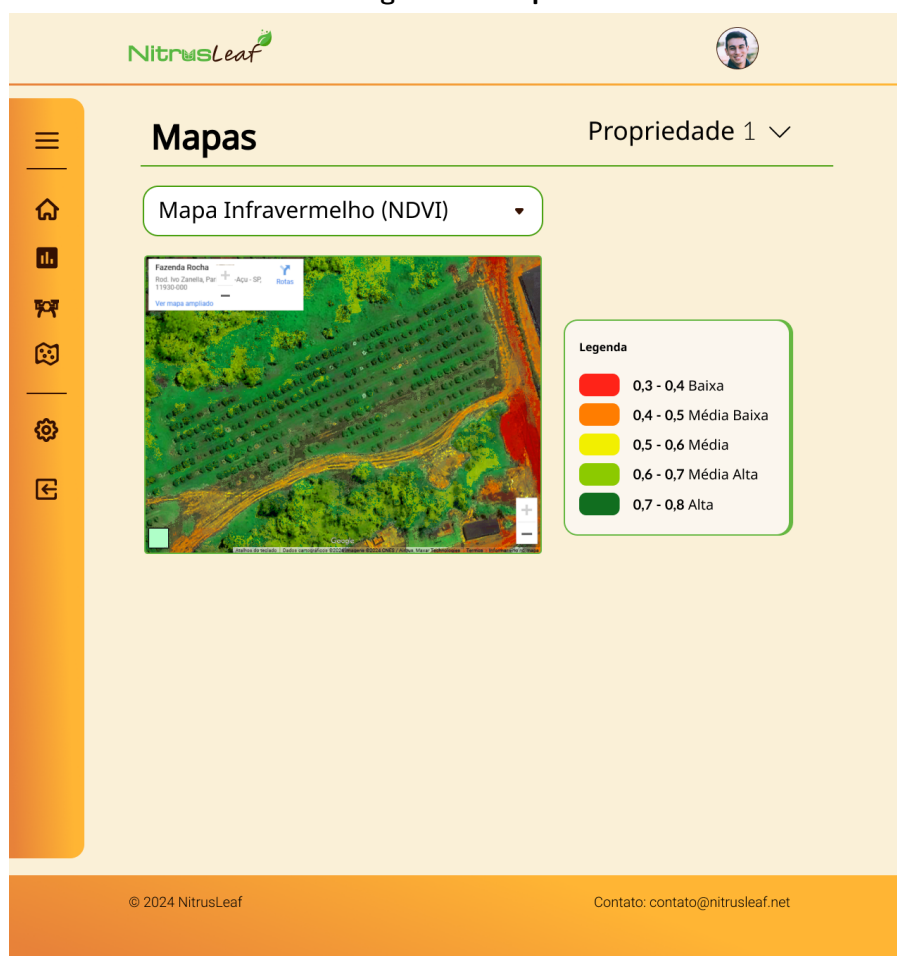


Fonte: Autoria Própria (2024)

Na tela de mapas Figura 5, o usuário pode escolher entre diferentes tipos de mapas, como o NDVI, um mapa via satélite que mostra a localização, um mapa com todas as mexericas e um mapa de calor que exhibe a concentração de possíveis deficiências.

O NDVI, ou Índice de Estado de Vegetação, é gerado a partir de imagens capturadas por drones e um gráfico de linhas que mostra o nível de NDVI para cada talhão ao longo de 12 meses. Esse índice mede a quantidade de energia refletida e absorvida pelas plantas, fornecendo informações sobre sua saúde com base nessa refletância. A luz visível (400 a 720 nm) é absorvida, enquanto o infravermelho próximo (720 a 1100 nm) é refletido em maior intensidade por plantas saudáveis. Plantas em estresse, desidratadas ou doentes absorvem mais luz infravermelha, o que afeta seu índice NDVI. Esse valor é calculado usando a fórmula:  $NDVI = (NIR - VIS) / (NIR + VIS)$  (Trindade; Volk; Rocha, 2021; Aegro, 2020).

Figura 5 – Mapas



Fonte: Autoria Própria (2024)

### Diagrama de classes

O diagrama de classes do nosso projeto Figura 6 começa com a Landing Page, que é a tela inicial exibida caso o usuário não esteja logado. Nessa tela, o usuário pode optar por fazer login ou cadastrar-se. A tela de login permite que o usuário insira seu e-mail ou telefone celular e senha, com a opção de recuperação de senha, caso necessário.

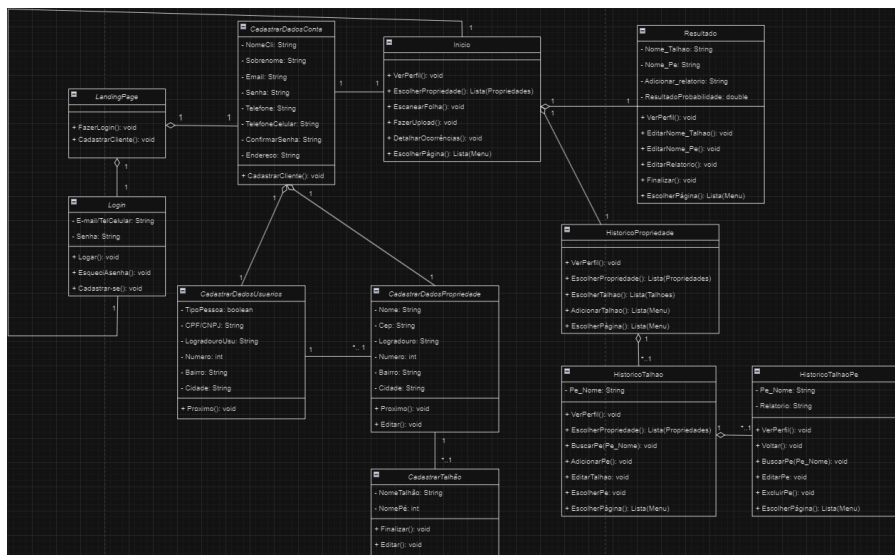
O processo de cadastro envolve a inserção de dados como nome, sobrenome, e-mail, senha, telefone celular, confirmação de senha e endereço. Após essa etapa, o usuário pode continuar o cadastro, especificando o tipo de pessoa (física ou jurídica), CPF ou CNPJ (dependendo do tipo), logradouro, número, bairro e cidade. Em seguida, o sistema permite que o usuário cadastre sua propriedade, incluindo informações como nome, CEP, logradouro, número, bairro e cidade da propriedade. Esse cadastro de propriedade possibilita também a edição de talhões, permitindo ao usuário adicionar o nome do talhão e o nome do pé, com opções de edição ou finalização do cadastro.

Ao escolher escanear uma folha ou fazer o upload de uma imagem, o sistema realiza a análise da imagem e exibe uma tela de resultado que mostra a probabilidade de deficiência identificada ou outras condições. O usuário pode então informar o nome do pé analisado, o talhão ao qual ele pertence e, se necessário, adicionar um relatório à análise. O sistema permite editar o nome do pé, o talhão ou o relatório da análise antes de finalizar o cadastro do resultado.

Há também uma funcionalidade de histórico da propriedade, onde o usuário pode selecionar

uma propriedade específica ou alternar para outro talhão, além de adicionar novos talhões. Ao escolher um talhão, o usuário consegue visualizar todos os pés cadastrados nele, podendo buscar um pé pelo nome, selecionar qualquer um dos pés, editar o talhão ou adicionar novos pés. Caso um pé específico seja selecionado, o usuário pode editar o nome, o relatório e, se necessário, excluí-lo do sistema.

### Figura 6 – Diagrama de Classe



**Fonte: Autoria Própria (2024)**

## MBD (Modelo de Banco de Dados)

Primeiramente, é criado o banco de dados ??, que é então utilizado para gerenciar os dados da aplicação. A seguir, são detalhadas as principais tabelas do banco:

- **Tabela usuarios:** Contém as informações dos usuários. Possui os seguintes campos:
  - id\_usuario: Chave primária do tipo int, com auto\_increment.
  - foto\_perfil: URL da foto de perfil, armazenado em varchar.
  - nome: Nome do usuário, varchar not null.
  - sobrenome: Sobrenome do usuário, varchar not null.
  - email: E-mail do usuário, varchar not null.
  - senha: Senha do usuário, varchar not null.
  - telefone: Telefone, varchar not null.
  - celular: Celular, varchar not null.
  - tipo\_pessoa: Tipo de pessoa, enum com valores “física” ou “jurídica”, not null.
  - cpf: CPF, armazenado em varchar, obrigatório para pessoas físicas.
  - cnpj: CNPJ, varchar, obrigatório para pessoas jurídicas.
  - nome\_fantasia: Nome fantasia da empresa, varchar.
  - logradouro, numero, bairro, cidade: Campos de endereço em varchar.
  - cep: CEP, varchar.
- **Tabela propriedades:** Armazena as informações das propriedades dos usuários.
  - id\_propriedade: Chave primária do tipo int, com auto\_increment.
  - id\_usuario: Chave estrangeira que referencia o usuário proprietário, tipo int.
  - nome\_propriedade, logradouro\_propriedade, numero\_propriedade, bairro\_propriedade, cep\_propriedade, cidade\_propriedade: Campos de identificação e localização, todos do tipo varchar.

- talhoes\_registrados: Total de talhões registrados, int com valor padrão 0.
- total\_pes: Total de pés cadastrados na propriedade, int com valor padrão 0.
- pes\_analisados: Total de pés analisados, int com valor padrão 0.
- pes\_diagnostics: Número de pés diagnosticados, int com valor padrão 0.

A chave estrangeira id\_usuario referencia a tabela usuarios.

- **Tabela talhoes:** Armazena as informações dos talhões.

- id\_talhao: Chave primária do tipo int, com auto\_increment.
- id\_propriedade: Chave estrangeira que referencia a propriedade à qual o talhão pertence.
- nome: Nome do talhão, varchar not null.
- especie\_fruta: Espécie da fruta, varchar not null.

A chave estrangeira id\_propriedade referencia a tabela propriedades.

- **Tabela pes:** Representa cada pé plantado no talhão.

- id\_pe: Chave primária do tipo int, com auto\_increment.
- id\_talhao: Chave estrangeira que referencia o talhão ao qual o pé pertence.
- nome: Nome do pé, varchar not null.
- situacao: Situação do pé, enum com valores “tratado”, “nao tratado” e “sem informacoes”, not null.

A chave estrangeira id\_talhao referencia a tabela talhoes.

- **Tabela fotos:** Armazena as fotos tiradas de cada pé para análise.

- id\_foto: Chave primária do tipo int, com auto\_increment.
- id\_pe: Chave estrangeira que referencia o pé da qual a foto foi tirada.
- id\_talhao: Chave estrangeira que referencia o talhão ao qual o pé pertence.
- url: URL da foto, varchar not null.
- data\_tirado: Data em que a foto foi tirada, date.
- resultado\_analise: Resultado da análise da imagem, varchar.

As chaves estrangeiras id\_pe e id\_talhao referenciam, respectivamente, as tabelas pes e talhoes.

- **Tabela relatorios:** Armazena relatórios de diagnóstico para cada pé.

- id\_relatorio: Chave primária do tipo int, com auto\_increment.
- id\_pe: Chave estrangeira que referencia o pé analisado.
- id\_foto: Chave estrangeira que referencia a foto utilizada no relatório.
- deficiencia\_cobre: Verifica deficiência de cobre, boolean com valor padrão false.
- deficiencia\_manganes: Verifica deficiência de manganês, boolean com valor padrão false.
- outros: Indica se o resultado foi adverso, boolean com valor padrão false.
- nao\_analisado: Indica se a planta ainda não foi analisada, boolean com valor padrão true.
- observacoes: Observações adicionais do usuário, varchar.
- data\_analise: Data em que a análise foi realizada, date not null.

As chaves estrangeiras id\_pe e id\_foto referenciam, respectivamente, as tabelas pes e fotos.

## CONCLUSÃO

Inicialmente, o projeto tem por objetivo buscar uma solução para as deficiências de minerais encontradas na mexeriqueira (Citrus reticulata), especificamente na variedade conhecida como

mexerica, e, conseqüentemente, apresentar uma alternativa ao problema utilizando tecnologia. Dessa forma, elaboramos um projeto cuja ideia central é criar uma aplicação capaz de identificar, em tempo real, a deficiência de minerais pela qual a planta está passando. Isso permitirá produzir um diagnóstico preciso, facilitando o processo de recuperação da planta, evitando a perda de frutos e otimizando o tempo dos produtores.

Diante disso, nos deparamos com algumas limitações ao longo da pesquisa, pois ela é restrita a apenas alguns países e às condições do solo. A falta de minerais na planta possui relação direta com a acidez do solo. Nosso estudo tem por objetivo identificar especificamente deficiências de manganês e cobre em plantas de *Citrus reticulata* (mexerica) através da análise foliar. Pesquisas mostram que uma planta com deficiência de manganês geralmente não apresenta deficiência de cobre e vice-versa. Uma análise mais aprofundada revela que a deficiência está diretamente ligada ao pH do solo. A carência de manganês pode ser identificada em um solo mais ácido, enquanto a deficiência de cobre pode se manifestar em um solo alcalino (Bruna, 2019; Machado, 2022).

## REFERÊNCIAS

AEGRO. **O que são mapas NDVI e como utilizá-los na fazenda**. Porto Alegre, RS: [s. n.], 2020. Blog aegro. Disponível em: <<https://blog.aegro.com.br/ndvi/>>. Acesso em: 29 mai. 2024.

AREGBE, Ikeoluwa; FARNSWORTH, Derek; SIMNITT, Skyler. **Citrus Greening, Hurricanes, and the Decline of the Florida Citrus Industry**. [S. l.: s. n.], 2024. Southern Ag Today. Disponível em: <<https://southernagtoday.org/2024/01/05/citrus-greening-hurricanes-and-the-decline-of-the-florida-citrus-industry/>>. Acesso em: 4 mai. 2024.

BRUNA, Jackellyne. **9 micronutrientes das plantas: como e quando utilizá-los**. Porto Alegre, RS: [s. n.], 2019. Blog aegro. Disponível em: <<https://blog.aegro.com.br/micronutrientes/#:~:text=0s%20sintomas%20de%20defici%C3%Aancia%20de%20mangan%C3%AAs%20podem%20frequentemente%20ser%20confundidos,do%20solo%20%C3%A9%20t%C3%A3o%20cr%C3%ADtico.&text=0%20pH%20do%20solo%20mais,folhas%20amareladas%20na%20sua%20lavoura.>>>. Acesso em: 30 mai. 2024.

BUENO, Newton; GASPAROTTO, Luadir. Sintomas de deficiências nutricionais em citros. **Embrapa**, Embrapa Amazônia Ocidental, p. 19, dez. 1999. ISSN 1517-2449. Disponível em: <<https://ainfo.cnptia.embrapa.br/digital/bitstream/item/64450/1/CircTec-06-1999.pdf>>. Acesso em: 19 abr. 2024.

CHRISTIN, Sylvain; HERVET, Éric; LECOMTE, Nicolas. Applications for deep learning in ecology. **Methods in Ecology and Evolution**, British Ecological Society(BES), p. 1632–1644, out. 2019. DOI: 10.1111/2041-210X.13256. Acesso em: 5 mai. 2024.

FUNDECITRUS. **Greening**. Araraquara, SP: [s. n.], 2018. Fundecitrus, ciência e sustentabilidade para a citrucultura. Disponível em: <<https://www.fundecitrus.com.br/doencas/greening>>. Acesso em: 26 abr. 2024.

GHORAI, Ankit Kumar *et al.* Image Processing Based Detection of Diseases and Nutrient Deficiencies in Plants. **SATSA Mukhapatra - Annual Technical Issue**, v. 25, p. 1–25, 2021. ISSN 0971-975X. Disponível em: <[https://www.researchgate.net/publication/349707825\\_Image\\_Processing\\_Based\\_Detection\\_of\\_Diseases\\_and\\_Nutrient\\_Deficiencies\\_in\\_Plants](https://www.researchgate.net/publication/349707825_Image_Processing_Based_Detection_of_Diseases_and_Nutrient_Deficiencies_in_Plants)>. Acesso em: 31 out. 2024.

MACHADO, Anderson Wolf. **Cobre - tudo o que você precisa saber sobre este adubo.**

[S. l.: s. n.], 2022. Agrolink. Disponível em:

<[https://www.agrolink.com.br/fertilizantes/nutrientes/cobre---tudo-o-que-voce-precisa-saber-sobre-este-adubo\\_468470.html](https://www.agrolink.com.br/fertilizantes/nutrientes/cobre---tudo-o-que-voce-precisa-saber-sobre-este-adubo_468470.html)>. Acesso em: 30 mai. 2024.

MUTHUSAMY, Sudhakar; RAMU, Swarna Priya. Computer Vision Based Machine Learning and Deep Learning Approaches for Identification of Nutrient Deficiency in Crops: A Survey. **Nature Environment and Pollution Technology**, v. 22, n. 3, p. 1387–1399, 2023. ISSN 2395-3454. DOI: <https://doi.org/10.46488/NEPT.2023.v22i03.025>.

QIN, Zhuwei *et al.* How convolutional neural networks see the world — A survey of convolutional neural network visualization methods. **Mathematical Foundations of Computing**, American Institute of Mathematical Sciences, v. 1, n. 2, p. 149–180, mai. 2018. DOI: [10.3934/mfc.2018008](https://doi.org/10.3934/mfc.2018008).

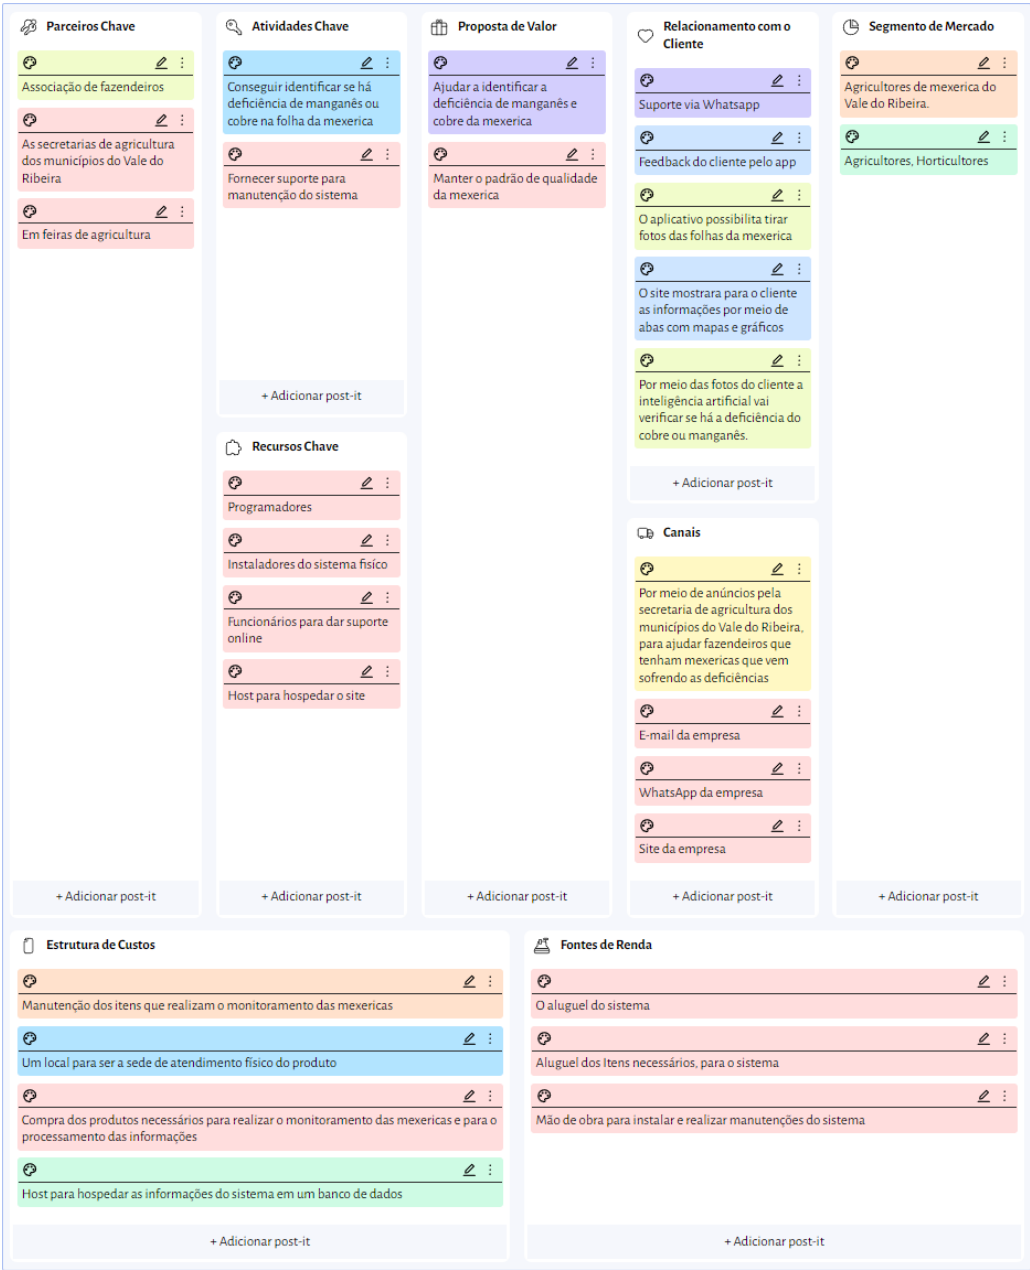
TRAN, Trung-Tin *et al.* A Comparative Study of Deep CNN in Forecasting and Classifying the Macronutrient Deficiencies on Development of Tomato Plant. **Applied Sciences**, v. 9, n. 8, 2019. DOI: <https://doi.org/10.3390/app9081601>.

TRINDADE, José Pedro Pereira; VOLK, Leandro Bochi da Silva; ROCHA, Danilo Serra da. Avaliação do índice normalizado de vegetação no monitoramento de sistema de unidades de manejo. **Bagé**, Embrapa Pecuária Sul, p. 31, mai. 2021. ISSN 1983-0467. Disponível em: <<https://ainfo.cnptia.embrapa.br/digital/bitstream/item/223511/1/BPD-47-online.pdf>>. Acesso em: 29 mai. 2024.



APÊNDICE A — MODELO DE NEGÓCIOS CANVAS

Figura 7 – Modelo de negócios Canvas



Fonte: Autoria Própria (2024)