

Classificação de Manganês e Cobre na Folha da Mexerica, Orientado por Redes Neurais

Classification of Manganese and Copper in Tangerine Leaves, Guided by Neural Networks

Fagundes. L { lucas.fagundes3@fatec.sp.gov.br }
Freitas. A { amanda.freitas14@fatec.sp.gov.br }
Freitas. V { valeria.freitas@fatec.sp.gov.br }
Medina. L { luiz.medina@fatec.sp.gov.br }

RESUMO

Este artigo tem como objetivo alinhar-se ao Objetivo de Desenvolvimento Sustentável (ODS) 2 — Fome Zero e Agricultura Sustentável da Agenda 2030 da ONU, visando reduzir perdas na produção agrícola e promover práticas agrícolas mais sustentáveis. A proposta apresentada busca auxiliar agricultores na identificação rápida e precisa de deficiências nutricionais em plantas, utilizando visão computacional para analisar imagens de folhas capturadas por drones ou enviadas pelos produtores. O trabalho descreve o desenvolvimento inicial do projeto NitrusLeaf, um aplicativo para celular e site, que emprega técnicas de Inteligência Artificial (IA) para identificar deficiências nutricionais de cobre e manganês em folhas de *Citrus reticulata* (mexerica). O treinamento da IA será realizado com redes neurais convolucionais (CNNs), utilizando um banco de dados composto por imagens de folhas com e sem deficiências. Espera-se que, ao final da pesquisa, o NitrusLeaf se consolide como uma ferramenta eficaz para apoiar a agricultura sustentável.

PALAVRAS-CHAVE: *Citrus reticulata*; Deficiência nutricional; Visão computacional; Manganês; Cobre.

ABSTRACT

This article aims to align with the Sustainable Development Goal (SDG) 2 — Zero Hunger and Sustainable Agriculture of the UN 2030 Agenda, aiming to reduce losses in agricultural production and promote more sustainable agricultural practices. The proposed application seeks to assist farmers in the rapid and accurate identification of nutritional deficiencies in plants, using computer vision to analyze images of leaves captured by drones or submitted by producers. This work presents the initial development of the NitrusLeaf project, a mobile app and website that utilizes Artificial Intelligence (AI) techniques to identify nutritional deficiencies of copper and manganese in *Citrus reticulata* (mandarin) leaves. The AI will be trained using convolutional neural networks (CNNs), employing a database of images of leaves with and without deficiencies. It is expected that, by the end of the research, NitrusLeaf will be consolidated as an effective tool to support sustainable agriculture.

KEYWORDS: *Citrus reticulata*; Nutritional deficiency; Computer Vision; Manganese; Copper.

INTRODUÇÃO

Vivemos em um mundo onde a comida não é suficiente para todos, e problemas como guerras e pobreza continuam a assolar diversas regiões. Esse mal perdura há muito tempo, e, em 1945, a Organização das Nações Unidas (ONU) foi criada para tentar combater esses desafios globais. Como parte dos esforços para enfrentar essas questões, a ONU lançou, em setembro de 2015, os Objetivos de Desenvolvimento Sustentável (ODS), definidos na Agenda 2030. Esse movimento global tem como metas principais erradicar a pobreza, proteger o meio ambiente e o clima, acabar com a fome e promover paz e prosperidade em todo o mundo. No presente projeto, buscamos reduzir as possíveis perdas de *Citrus reticulata* (mexerica), o que se alinha ao ODS 2 — Fome Zero e Agricultura Sustentável. Nosso foco é garantir uma maior produtividade das mexericas, contribuindo assim para a segurança alimentar e a sustentabilidade agrícola.(Fundecitrus, 2018).

Atualmente, a produção de citros está em declínio em todo o mundo, devido a condições climáticas adversas, além de pragas e doenças que afetam essas culturas. Algumas dessas doenças

têm alcance global, como *Phytophthora citrophthora*, *Xylella fastidiosa*, o cancro cítrico e o greening, também conhecido como HLB (Huanglongbing). Nas Américas do Sul e do Norte, há uma alta incidência do greening. Nos Estados Unidos, por exemplo, a colheita do último ano foi menor do que o esperado, resultado da combinação de infestações por greening e furacões (Aregbe; Farnsworth; Simnitt, 2024).

No Brasil, a taxa de infecção por greening também é significativa. Essa doença ataca todas as variedades de citros e, uma vez infectada, a planta não tem cura. Plantas jovens contaminadas geralmente não chegam a produzir frutos, enquanto plantas adultas sofrem queda prematura de frutos e, eventualmente, definhamento. Uma das principais bactérias causadoras do greening no Brasil é a *Candidatus Liberibacter asiaticus*, responsável por 99% dos casos registrados no país. A bactéria é transmitida pelo psíldeo *Diaphorina citri*, também conhecido como psíldeo-asiático-dos-citros, um inseto de coloração branco-acinzentada com manchas escuras nas asas, que mede entre 2 e 3 mm. Esse inseto é especialmente frequente nos pomares durante as épocas de brotação das plantas. O estado de São Paulo é uma das regiões mais afetadas pelo greening, conforme evidenciado pelo Programa Nacional de Prevenção e Controle ao HLB (PNCHLB), que exige a eliminação de plantas com menos de oito anos contaminadas pelo HLB, o que inclui áreas como o Vale do Ribeira, também no estado de São Paulo (Fundecitrus, 2018).

O HLB, popularmente conhecido como greening, teve origem na Ásia há mais de 100 anos. No Brasil, a doença foi identificada em 2004, nas regiões Centro e Leste do Estado de São Paulo, e desde então se espalhou para todas as áreas citrícolas do estado, bem como para pomares em Minas Gerais e Paraná. Além disso, a doença se expandiu para outros países da América do Sul, como Argentina e Paraguai (Fundecitrus, 2018).

Como o greening é uma doença incurável, a remoção imediata das plantas infectadas é necessária após a detecção em um campo, a fim de reduzir o risco de contaminação para as plantas ao redor. Infelizmente, pouco pode ser feito para salvar plantas infectadas. Os sintomas do greening incluem folhas amareladas quando jovens, mosqueadas com pintas ou malhas escuras quando maduras. Além disso, as folhas afetadas tendem a cair, sendo substituídas por outras em posição vertical. Por isso, a distinção entre o greening e outras doenças ou condições com sintomas semelhantes é crucial, para evitar a eliminação de plantas que poderiam ser salvas. Duas das condições causadas por deficiência de nutrientes que apresentam semelhança com os sintomas do greening são a deficiência de cobre e a de manganês. A deficiência de cobre manifesta-se por folhas pequenas e deformadas no novo ciclo de crescimento, com nervuras verdes bem definidas sobre uma coloração mais clara. As plantas também podem apresentar folhas maiores que o normal, além de bolsas de goma nos ramos novos e na casca dos frutos. Já a deficiência de manganês se caracteriza por folhas novas de tamanho quase normal, perda de brilho e clorose — uma tonalidade amarelada entre as nervuras, que permanecem verdes (Fundecitrus, 2018; Bueno; Gasparotto, 1999).

Nosso projeto tem como objetivo analisar as deficiências de cobre e manganês nas folhas de *Citrus reticulata*. Essas duas condições foram selecionadas por apresentarem semelhanças com alguns dos sintomas do greening, como o amarelamento e o crescimento anormal das folhas. Utilizando a análise de imagens, buscamos identificar se uma folha apresenta sinais de uma dessas deficiências nutricionais. Com base no diagnóstico, o agricultor poderá adotar as medidas corretivas adequadas, como a verificação do estado nutricional do solo e a aplicação de fertilizantes de forma precisa e equilibrada, contribuindo para a saúde da planta e a maximização da produtividade.

Atualmente, a Inteligência Artificial (IA) é utilizada em diversas áreas do mercado de trabalho, desde o setor de saúde até os anúncios que vemos diariamente. Ela tem sido aplicada para aumentar a eficiência e a qualidade, proporcionando resultados mais precisos em uma ampla gama de situações.

O objetivo da IA é operar de forma autônoma, oferecendo respostas exatas para cada contexto, sem a necessidade de intervenção humana. Assim, a adoção da IA em grandes empresas, hospitais e em outros setores que buscam automação está se tornando cada vez mais comum e significativa.

O sistema desenvolvido será um aplicativo móvel que utilizará Inteligência Artificial (IA) para identificar deficiências de manganês e cobre nas folhas de mexerica. Com essa ferramenta, o usuário poderá apontar a câmera do celular para a folha, permitindo que a IA analise possíveis sinais de deficiência, como clorose ou uma coloração verde intensa. Com base nessa análise, o sistema indicará se a folha apresenta sintomas de deficiência nutricional ou se está saudável, proporcionando um diagnóstico prático e acessível diretamente no campo.

A parte da Inteligência Artificial (IA) que nosso projeto utilizará será a visão computacional, que permite que a máquina "veja" visualmente e identifique diversos dados a partir das imagens. Para aplicar a visão computacional, são necessárias duas tecnologias-chave: redes neurais convolucionais e aprendizado de máquina profundo, conhecido como Deep Learning. Essas ferramentas possibilitam que a máquina reconheça padrões específicos. A rede neural convolucional é utilizada em contextos que exigem visão computacional e é inspirada na organização hierárquica do córtex visual humano, sendo composta por camadas interconectadas de neurônios (Qin *et al.*, 2018). Por outro lado, o Deep Learning é uma evolução do aprendizado de máquina, consistindo em uma rede neural com múltiplas camadas. Com o Deep Learning, basta indicar se uma imagem contém uma folha de Citrus reticulata saudável ou com deficiência, e, ao fornecer muitas imagens rotuladas, a máquina aprenderá a identificar os padrões. Em contraste, no aprendizado de máquina tradicional, é necessário descrever de forma programática como é a folha saudável, especificando as características dos pixels na imagem do padrão que se deseja que a máquina reconheça (Christin; Hervet; Lecomte, 2019).

OBJETIVO

A agricultura de citros enfrenta diversos tipos de doenças, que podem ser identificadas a partir da observação de deformidades físicas e alterações de pigmentação em suas folhas, cascas e frutos, além da presença de pragas que afetam a qualidade final do alimento. A análise foliar é uma técnica comum utilizada para diagnosticar deficiências nutricionais em plantas, que consiste na coleta de folhas seguida pela análise química para determinar a concentração de determinados nutrientes. No entanto, esse processo pode ser demorado e requer habilidades técnicas especializadas. A utilização de inteligência artificial (IA) para buscar padrões visuais pode facilitar a determinação desse diagnóstico.

O projeto tem como objetivo desenvolver um sistema capaz de reconhecer deficiências de manganês e cobre em folhas de mexerica a partir da análise de fotos de manchas, utilizando IA para facilitar um diagnóstico direto ao agricultor. Os objetivos principais são:

1. **Aprofundar na coleta de informações sobre os sintomas das deficiências nutricionais específicas da mexerica.**
2. **Desenvolver um banco de imagens com uma variedade de níveis de deficiência de manganês e cobre para análise do problema.**
3. **Realizar o treinamento da IA utilizando uma arquitetura de rede Neural Convolucional (CNNs).**
4. **Implementar um sistema que possibilite a identificação técnica das deficiências por meio de Inteligência Artificial, utilizando imagens digitais capturadas pelos próprios agricultores.**

Além dos objetivos principais, este projeto também busca atingir os seguintes objetivos específicos:

1. **Desenvolver um sistema de visão computacional para identificar sintomas de deficiências nutricionais em imagens de folhas de mexericas, permitindo uma análise detalhada e precisa das condições de saúde da planta.**
2. **Criar uma funcionalidade que permita ao usuário analisar a folha da mexerica ao apontar a câmera do celular para a planta, possibilitando que a IA identifique e interprete o estado de saúde da planta em tempo real.**
3. **Após a análise do estado da planta, habilitar o cadastro do diagnóstico pelo usuário, com a opção de registrar o talhão e o número da planta para facilitar o acompanhamento e controle.**
4. **Implementar uma funcionalidade de histórico para monitoramento, permitindo que o usuário visualize a evolução do estado das plantas e dos talhões ao longo do tempo, com a possibilidade de comparar estados anteriores e atuais.**
5. **Desenvolver, se possível, uma funcionalidade para a captura de imagens da plantação por drones, possibilitando a identificação de áreas mais ou menos saudáveis, facilitando a detecção de plantas potencialmente doentes.**
6. **Incluir um mapa interativo que mostre a localização de cada planta nos talhões, com legendas que indiquem a situação de saúde, número da planta e do talhão.**
7. **Criar um mapa de calor para destacar áreas críticas, com cores representando diferentes situações, como deficiência de manganês, deficiência de cobre e outras deficiências, facilitando a visualização dos pontos de foco e concentração de problemas.**
8. **Realizar uma análise de precisão do sistema desenvolvido, comparando-o com os métodos tradicionais de análise de solo e folhas, para validar a eficácia do sistema.**
9. **Fornecer recomendações práticas e úteis com base nos resultados obtidos, para que os agricultores possam tratar de forma direcionada as deficiências detectadas, caso necessário.**

ESTADO DA ARTE

Entre os muitos desafios enfrentados pelos agricultores, a deficiência de minerais nas plantas é uma preocupação significativa, pois pode resultar em perdas de produtividade e qualidade dos cultivos. A mexerica (*Citrus reticulata*) é uma das culturas suscetíveis a deficiências minerais, o que pode afetar seu crescimento, desenvolvimento e produção.

O artigo de Muthusamy e Ramu (2023) discute avanços recentes nas tecnologias de visão computacional, aprendizado de máquina (ML) e aprendizado profundo (DL), que têm sido aplicadas ao monitoramento agrícola para melhorar a produtividade e a qualidade das colheitas. Entre as tecnologias abordadas, destacam-se imagens de satélite, sensoriamento remoto, Internet das Coisas (IoT), dispositivos de sensor e Veículos Aéreos Não Tripulados (VANTs). Esses sistemas são utilizados para capturar dados visuais e detectar deficiências nutricionais em tempo real, permitindo um diagnóstico precoce e aumentando a eficiência na aplicação de insumos agrícolas.

O artigo cita trabalhos que demonstram como a visão computacional, combinada com ML e DL, pode identificar padrões visuais como coloração, textura e bordas em imagens de plantas. Esse exemplo ilustra como essas técnicas permitem um diagnóstico não invasivo, usando câmeras digitais e algoritmos avançados para diferenciar entre folhas saudáveis e folhas com deficiência nutricional.


Com base nesses avanços, é viável que o projeto NitrusLeaf implemente um sistema semelhante, utilizando smartphones e visão computacional para capturar e analisar imagens de folhas de mexerica.

Com o suporte de algoritmos de ML/DL, o sistema pode processar essas imagens para identificar deficiências específicas, como de cobre e manganês, diretamente no campo.

O artigo de (Ghorai *et al.*, 2021) explora um pipeline detalhado Figura 1 para identificar doenças e deficiências nutricionais em plantas, baseado em técnicas de processamento de imagem. Esse pipeline, ou sequência organizada de etapas, permite a análise automatizada e eficiente de imagens de plantas, produzindo diagnósticos agrícolas precisos. O pipeline descrito no artigo inclui as seguintes fases: Aquisição de imagem, Pré-processamento, Segmentação, Extração de características, Classificação e, finalmente, Detecção e Diagnóstico. Cada fase depende da anterior e contribui para refinar e analisar os dados, de modo a produzir uma resposta confiável sobre a condição da planta.

- **Aquisição de imagem:** Envolve a captura de imagens de plantas utilizando câmeras, drones (Veículos Aéreos Não Tripulados - VANTs) ou dispositivos móveis. Essa etapa assegura que as imagens tenham qualidade suficiente para as fases subsequentes do processamento.
- **Pré-processamento:** Aqui, técnicas de correção de ruído, ajuste de contraste e brilho, além de redimensionamento e rotação, são aplicadas para melhorar a qualidade da imagem e facilitar a segmentação.
- **Segmentação de imagem:** É feita para isolar a folha ou parte relevante da planta, separando-a do fundo. Técnicas comuns incluem limiarização, segmentação por cor e abordagens de aprendizado de máquina.
- **Extração de características:** Essa etapa analisa e extrai informações importantes, como cor, textura e forma, que são essenciais para diferenciar entre folhas saudáveis e afetadas. Métodos como histogramas de cor e a Matriz de Co-ocorrência de Níveis de Cinza (GLCM) são comumente usados.
- **Classificação:** Modelos de aprendizado de máquina ou redes neurais profundas (como CNNs e SVMs) são empregados para classificar as imagens, diferenciando as folhas saudáveis das que apresentam deficiências ou doenças.
- **Detecção e Diagnóstico:** A última etapa envolve o diagnóstico da condição da planta, onde é identificada a doença ou deficiência nutricional específica, e recomendações são geradas com base nos resultados da classificação.

Figura 1 – Esquema do pipeline para detecção de doenças em plantas baseada em imagens



Fonte: Adaptado de (Ghorai *et al.*, 2021)

Além disso, o artigo explora técnicas não intrusivas para a detecção de deficiências nutricionais, utilizando métodos avançados de análise de imagens. Por exemplo, uma tabela destaca o uso do sistema de cores RGB (Red, Green, Blue) para identificar deficiências de nutrientes, incluindo a deficiência de manganês em citrus. Essa abordagem reforça a viabilidade do projeto NitrusLeaf, que

tem como objetivo identificar deficiências de cobre e manganês nas folhas de mexerica. Ao adotar essas tecnologias e adaptar o pipeline descrito, o NitrusLeaf poderá se consolidar como uma solução eficaz e prática para diagnósticos agrícolas baseados em visão computacional.

O artigo de Tran *et al.* (2019) utiliza os modelos Inception-ResNet v2, Autoencoder de Rede Neural Convolutacional (CNN), e uma combinação desses dois modelos por meio de Ensemble Averaging para melhorar a detecção precoce de deficiências nutricionais de cálcio, nitrogênio e potássio em plantações de tomate. A identificação rápida dessas deficiências é essencial, pois a falta de intervenção pode levar a condições mais graves, incluindo doenças que afetam a produtividade e a saúde das plantas. Para garantir que os modelos fossem treinados com imagens robustas e representativas, os autores aplicaram técnicas de pré-processamento e aumento de dados (data augmentation), como ajuste de ângulo, brilho e contraste. Essas técnicas aumentaram a diversidade visual do conjunto de dados, ajudando os modelos a generalizar melhor e a detectar padrões de deficiência com mais precisão.

A escolha dos modelos Inception-ResNet v2 e Autoencoder foi motivada pela capacidade dessas arquiteturas em capturar características visuais complexas nas folhas e nos frutos, essenciais para distinguir entre deficiências nutricionais que compartilham sintomas visuais semelhantes. O Inception-ResNet v2, por exemplo, combina as vantagens das redes Inception e ResNet, permitindo uma análise detalhada de padrões locais e globais na imagem. Já o Autoencoder oferece uma estrutura de compressão e reconstrução útil para destacar anomalias visuais, como as causadas por deficiências. O estudo usou um conjunto de 571 imagens de tomates cultivados em estufas, das quais 80% (461 imagens) foram destinadas ao treinamento e 20% (110 imagens) para a validação dos modelos. Após extensivos testes, os resultados mostraram que o Inception-ResNet v2 obteve uma precisão de 87,27%, o Autoencoder alcançou 79,09%, e a técnica de Ensemble Averaging conseguiu uma precisão de 91%.

As abordagens e metodologias deste artigo são relevantes para nosso projeto, pois ambos compartilham o foco em visão computacional e aprendizado profundo para a detecção de deficiências nutricionais em plantas. Enquanto o artigo de Tran *et al.* se concentra em deficiências de nitrogênio e potássio em folhas de tomate, nosso projeto utiliza técnicas similares para identificar deficiências de cobre e manganês em folhas de mexerica. Assim, este trabalho oferece uma base metodológica útil, especialmente na escolha de modelos de CNN e na importância de uma abordagem de ensemble para melhorar a precisão no diagnóstico.

Esses resultados indicam que, com o uso apropriado das tecnologias discutidas, nosso projeto NitrusLeaf poderá alcançar resultados satisfatórios. Aproveitando as tecnologias descritas, buscamos oferecer uma funcionalidade avançada ao sistema, permitindo a identificação precisa de deficiências minerais, como as de manganês e cobre, por meio da análise de imagens capturadas pelos usuários.

METODOLOGIA

1 METODOLOGIA

O desenvolvimento do projeto será conduzido em etapas que seguem a metodologia de desenvolvimento ágil (*Scrum*), permitindo uma adaptação flexível aos requisitos ao longo do processo. Além disso, a Linguagem UML será utilizada para elaborar os diagramas de classes, objetos e casos de uso. As etapas principais incluem:

1.1 COLETA DE REQUISITOS E DESIGN

O *Figma* será utilizado para o desenvolvimento de protótipos de baixa e alta fidelidade das interfaces da aplicação, garantindo uma visualização clara dos requisitos funcionais e de usabilidade.

1.2 DESENVOLVIMENTO FRONT-END

O código será estruturado com *HTML* e *CSS* para a definição de layout e estilo, enquanto o *JavaScript* será utilizado para proporcionar interatividade. O *Node.js* será empregado para a criação de componentes reutilizáveis, melhorando a eficiência e a modularidade do código.

1.3 DESENVOLVIMENTO BACK-END E BANCO DE DADOS

O DER do banco de dados será modelado no *brModelo* e implementado no *MySQL WorkBench* e *XAMPP*, garantindo a correta estruturação dos dados. A interação entre *front-end* e *back-end* será implementada utilizando *Python* para a integração da visão computacional e *Node.js* no computador. Para o *mobile*, o *React Native* será utilizado para criar uma API eficiente.

1.4 TESTES E VALIDAÇÃO

Após a implementação, serão realizados testes automatizados e manuais para validar o funcionamento correto de cada parte do sistema. Ferramentas como *Selenium* poderão ser utilizadas para automatizar os testes de interface.

1.5 PUBLICAÇÃO E ACOMPANHAMENTO

O sistema será inicialmente implementado na plataforma *web*, com desenvolvimento do *front-end* e *back-end*. Em uma versão futura, algumas funções disponíveis na versão *web* serão adaptadas para o *mobile*, permitindo o uso do aplicativo no campo para escanear folhas em tempo real e receber feedback instantâneo. Serão garantidas fácil escalabilidade e manutenção, com ajustes realizados com base no feedback dos usuários após a implantação.

RESULTADOS PRELIMINARES

Após aplicar os métodos descritos, foram alcançados os seguintes resultados: a criação do site do projeto, utilizando HTML, CSS, JavaScript e NODE.JS, a criação do Diagrama de Classe e Diagrama de Objeto, além do banco de dados físico (MBD).

Prototipação do aplicativo no Figma

A Figura 2 apresenta a tela de Landing Page do projeto, que permite você se logar ou cadastrar.

Figura 2 – Landing Page



Fonte: Autoria Própria (2024)

A tela inicial Figura 3 oferece as opções de escanear uma folha com a câmera do celular ou fazer o upload de uma imagem para análise. Abaixo dessas opções, há um gráfico de pizza que mostra a porcentagem das ocorrências totais: amarelo para manganês, laranja-avermelhado para cobre e cinza para “adversos” (casos sem deficiência de cobre ou manganês). No lado direito, um quadro exibe análises recentes, incluindo o número total de plantas analisadas, tratadas e plantadas. No canto esquerdo, um menu permite acesso a outras telas do aplicativo, como histórico, drone e configurações gerais.

Figura 3 – Tela Início



Fonte: Autoria Própria (2024)

Ao selecionar “escanear folha”, o usuário deverá apontar a câmera para a folha escolhida. Caso opte por fazer o upload de uma imagem, o aplicativo iniciará a análise e, ao concluir, abrirá a tela Figura 4 mostrando a probabilidade da deficiência identificada. O usuário deve selecionar a planta analisada, o talhão ao qual pertence e pode adicionar um relatório, se necessário, antes de finalizar.

Figura 4 – Cadastro Diagnóstico

The screenshot displays the 'Resultado' (Result) screen of the NitrusLeaf application. The interface features a top navigation bar with the NitrusLeaf logo and a user profile icon. A vertical sidebar on the left contains icons for home, statistics, reports, settings, and a back button. The main content area is titled 'Resultado' and contains a form for recording a diagnosis. The form includes a table with columns for 'Nome Talhão' (Plot Name), 'Nome Pé' (Plant Name), and 'Editar' (Edit). The table has two rows: 'Talhão 1' and 'Pé 1'. Below the table is a text input field labeled 'Adicionar relatório...' (Add report...) and a green 'Finalizar' (Finish) button. To the right of the form, a large red circular progress indicator shows '92%' completion, with the text 'Deficiência de Cobre' (Copper Deficiency) below it. The footer of the app shows the copyright '© 2024 NitrusLeaf' and the contact email 'contato@nitrusleaf.net'.

Nome Talhão	Nome Pé	Editar
Talhão 1	Pé 1	
<input type="text" value="Adicionar relatório..."/>		

Finalizar

92% Deficiência de Cobre

Fonte: Autoria Própria (2024)

Para verificar as plantas cadastradas no aplicativo, o usuário acessa a tela de histórico Figura 5. Nessa tela, é possível ver a quantidade de plantas cadastradas em cada talhão, selecionar a propriedade sendo verificada, bem como visualizar o número de plantas analisadas até o momento. No lado direito, uma janela exibe o total de talhões e plantas registrados, além do número de plantas analisadas e diagnosticadas.

Figura 5 – Tela Relatórios




Fonte: Autoria Própria (2024)

Na tela de mapas Figura 6, o usuário pode escolher entre diferentes tipos de mapas, como o NDVI, um mapa via satélite que mostra a localização, um mapa com todas as mexericas e um mapa de calor que exhibe a concentração de possíveis deficiências.

O NDVI, ou Índice de Estado de Vegetação, é gerado a partir de imagens capturadas por drones e um gráfico de linhas que mostra o nível de NDVI para cada talhão ao longo de 12 meses. Esse índice mede a quantidade de energia refletida e absorvida pelas plantas, fornecendo informações sobre sua saúde com base nessa refletância. A luz visível (400 a 720 nm) é absorvida, enquanto o infravermelho próximo (720 a 1100 nm) é refletido em maior intensidade por plantas saudáveis. Plantas em estresse, desidratadas ou doentes absorvem mais luz infravermelha, o que afeta seu índice NDVI. Esse valor é calculado usando a fórmula: $NDVI = (NIR - VIS) / (NIR + VIS)$ (Trindade; Volk; Rocha, 2021; Aegro, 2020).

Figura 6 – Mapas

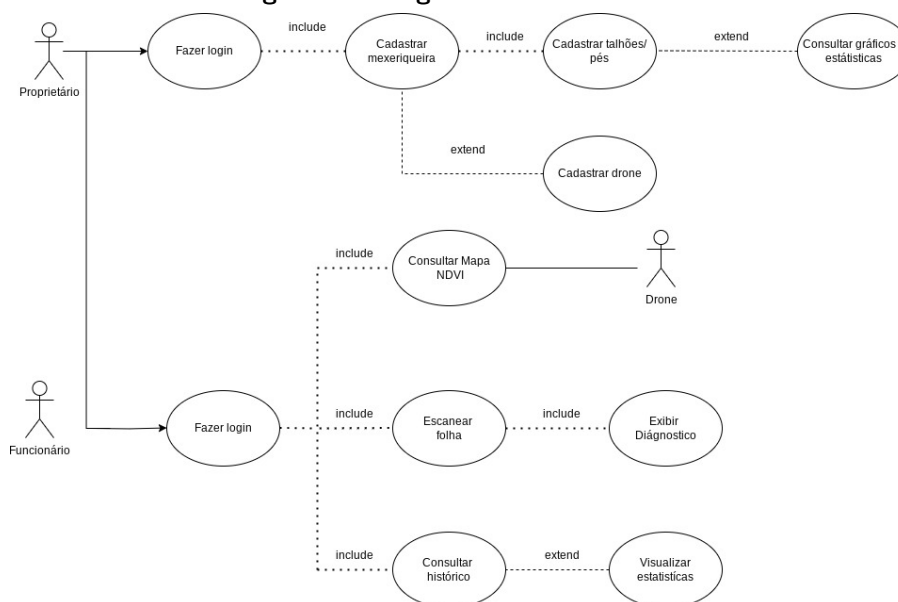


Fonte: Autoria Própria (2024)

Diagrama de Caso de Uso

O DCU do projeto, ou Diagrama de Caso de Uso, é utilizado para representar as relações entre os atores (usuários do sistema) e as funcionalidades oferecidas pelo projeto. Conforme ilustrado na Figura 7, o diagrama mostra que o proprietário é responsável por cadastrar as mexeriqueiras e os talhões, podendo também se quiser cadastrar drones, consultar gráficos e estatísticas da propriedade. Já o funcionário é encarregado de escanear as folhas, seja utilizando a câmera ou fazendo o upload de imagens. O aplicativo processará essas imagens e fornecerá um diagnóstico baseado nelas. Além disso, o funcionário pode consultar o mapa NDVI gerado pelos drones, acessar o histórico e visualizar estatísticas. Por sua vez, as funções do drone incluem capturar fotos do local e gerar um mapa NDVI.

Figura 7 – Diagrama de Caso de Uso



Fonte: Autoria Própria (2024)

Diagrama de classes

O diagrama de classes do nosso projeto Figura 8 começa com a Landing Page, que é a tela inicial exibida caso o usuário não esteja logado. Nessa tela, o usuário pode optar por fazer login ou cadastrar-se. A tela de login permite que o usuário insira seu e-mail ou telefone celular e senha, com a opção de recuperação de senha, caso necessário.

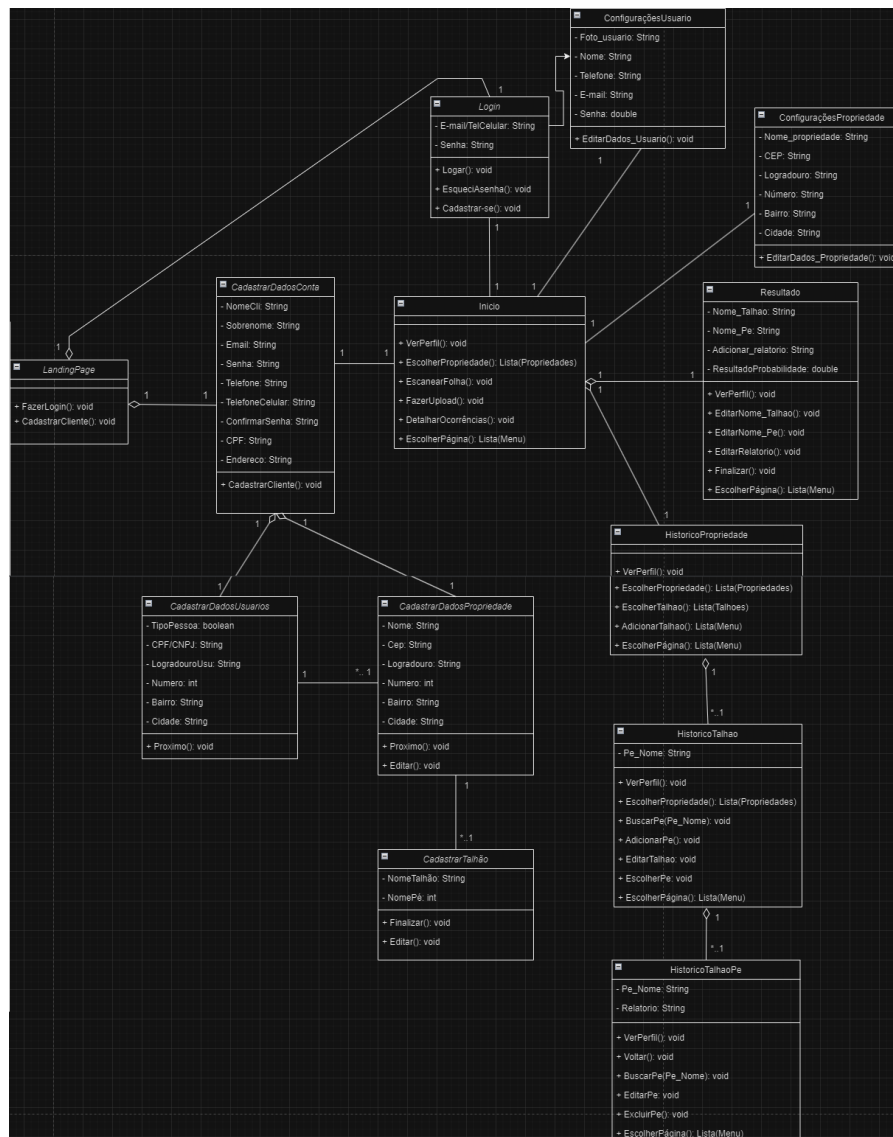
O processo de cadastro envolve a inserção de dados como nome, sobrenome, e-mail, senha, telefone celular, confirmação de senha e endereço. Após essa etapa, o usuário pode continuar o cadastro, especificando o tipo de pessoa (física ou jurídica), CPF ou CNPJ (dependendo do tipo), logradouro, número, bairro e cidade. Em seguida, o sistema permite que o usuário cadastre sua propriedade, incluindo informações como nome, CEP, logradouro, número, bairro e cidade da propriedade. Esse cadastro de propriedade possibilita também a edição de talhões, permitindo ao usuário adicionar o nome do talhão e o nome do pé, com opções de edição ou finalização do cadastro.

Ao escolher escanear uma folha ou fazer o upload de uma imagem, o sistema realiza a análise da imagem e exibe uma tela de resultado que mostra a probabilidade de deficiência identificada ou outras condições. O usuário pode então informar o nome do pé analisado, o talhão ao qual ele pertence e, se necessário, adicionar um relatório à análise. O sistema permite editar o nome do pé, o talhão ou o relatório da análise antes de finalizar o cadastro do resultado.

Há também uma funcionalidade de histórico da propriedade, onde o usuário pode selecionar uma propriedade específica ou alternar para outro talhão, além de adicionar novos talhões. Ao escolher um talhão, o usuário consegue visualizar todos os pés cadastrados nele, podendo buscar um pé pelo nome, selecionar qualquer um dos pés, editar o talhão ou adicionar novos pés. Caso um pé específico seja selecionado, o usuário pode editar o nome, o relatório e, se necessário, excluí-lo do sistema.

Há também a tela Configurações do Usuário, que exibe todos os dados cadastrados, permitindo que o usuário edite suas informações, caso necessário.

Figura 8 – Diagrama de Classe

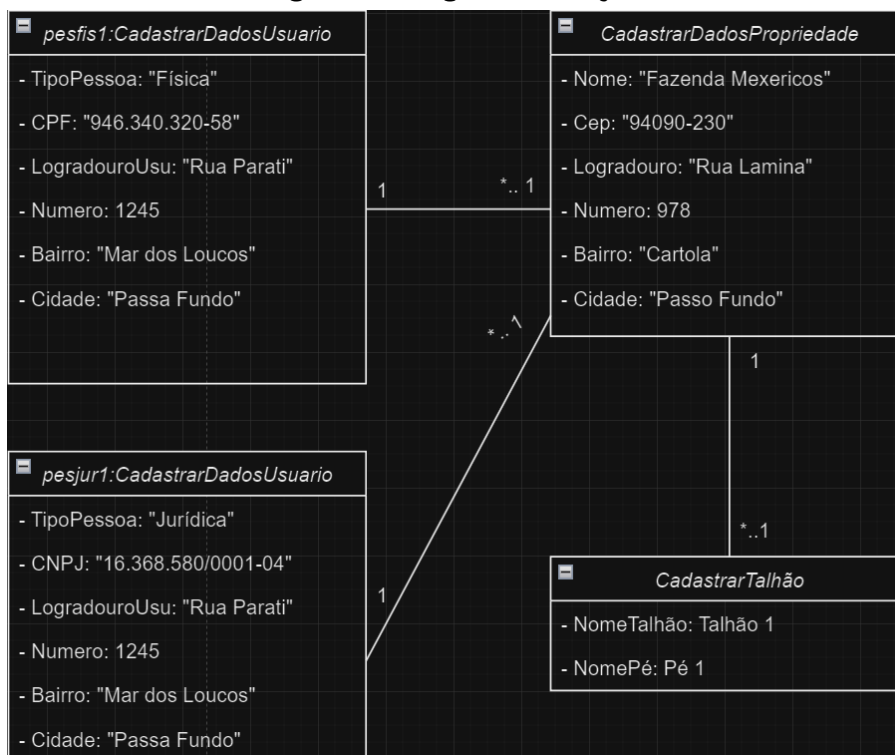


Fonte: Autoria Própria (2024)

Diagrama de Objetos

O diagrama de objetos do nosso projeto Figura 9 ilustra o processo de cadastro do usuário, da propriedade e do talhão, destacando as diferenças entre usuários do tipo físico e jurídico.

Figura 9 – Diagrama de Objetos



Fonte: Autoria Própria (2024)

MBD (Modelo de Banco de Dados)

Primeiramente, é criado o banco de dados, que é então utilizado para gerenciar os dados da aplicação. A seguir, são detalhadas as principais tabelas do banco, e na Figura 10 temos o DER do banco de dados físico que será descrito abaixo:

- **Tabela usuarios:** Contém as informações dos usuários. Possui os seguintes campos:
 - id_usuario: Chave primária do tipo int, com auto_increment.
 - foto_perfil: URL da foto de perfil, armazenado em varchar.
 - nome: Nome do usuário, varchar not null.
 - sobrenome: Sobrenome do usuário, varchar not null.
 - email: E-mail do usuário, varchar not null.
 - senha: Senha do usuário, varchar not null.
 - telefone: Telefone, varchar not null.
 - celular: Celular, varchar not null.
 - tipo_pessoa: Tipo de pessoa, enum com valores “física” ou “jurídica”, not null.
 - cpf: CPF, armazenado em varchar, obrigatório para pessoas físicas.
 - cnpj: CNPJ, varchar, obrigatório para pessoas jurídicas.
 - nome_fantasia: Nome fantasia da empresa, varchar.
 - logradouro, numero, bairro, cidade: Campos de endereço em varchar.
 - cep: CEP, varchar.
- **Tabela propriedades:** Armazena as informações das propriedades dos usuários.
 - id_propriedade: Chave primária do tipo int, com auto_increment.
 - id_usuario: Chave estrangeira que referencia o usuário proprietário, tipo int.
 - nome_propriedade, logradouro_propriedade, numero_propriedade, bairro_propriedade, cep_propriedade, cidade_propriedade: Campos de identificação e localização,

todos do tipo varchar.

- talhoes_registrados: Total de talhões registrados, int com valor padrão 0.
- total_pes: Total de pés cadastrados na propriedade, int com valor padrão 0.
- pes_analisados: Total de pés analisados, int com valor padrão 0.
- pes_diagnosticados: Número de pés diagnosticados, int com valor padrão 0.

A chave estrangeira id_usuario referencia a tabela usuarios.

▪ **Tabela talhoes:** Armazena as informações dos talhões.

- id_talhao: Chave primária do tipo int, com auto_increment.
- id_propriedade: Chave estrangeira que referencia a propriedade à qual o talhão pertence.
- nome: Nome do talhão, varchar not null.
- especie_fruta: Espécie da fruta, varchar not null.

A chave estrangeira id_propriedade referencia a tabela propriedades.

▪ **Tabela pes:** Representa cada pé plantado no talhão.

- id_pe: Chave primária do tipo int, com auto_increment.
- id_talhao: Chave estrangeira que referencia o talhão ao qual o pé pertence.
- nome: Nome do pé, varchar not null.
- situacao: Situação do pé, enum com valores “tratado”, “nao tratado” e “sem informacoes”, not null.

A chave estrangeira id_talhao referencia a tabela talhoes.

▪ **Tabela fotos:** Armazena as fotos tiradas de cada pé para análise.

- id_foto: Chave primária do tipo int, com auto_increment.
- id_pe: Chave estrangeira que referencia o pé da qual a foto foi tirada.
- id_talhao: Chave estrangeira que referencia o talhão ao qual o pé pertence.
- url: URL da foto, varchar not null.
- data_tirado: Data em que a foto foi tirada, date.
- resultado_analise: Resultado da análise da imagem, varchar.

As chaves estrangeiras id_pe e id_talhao referenciam, respectivamente, as tabelas pes e talhoes.

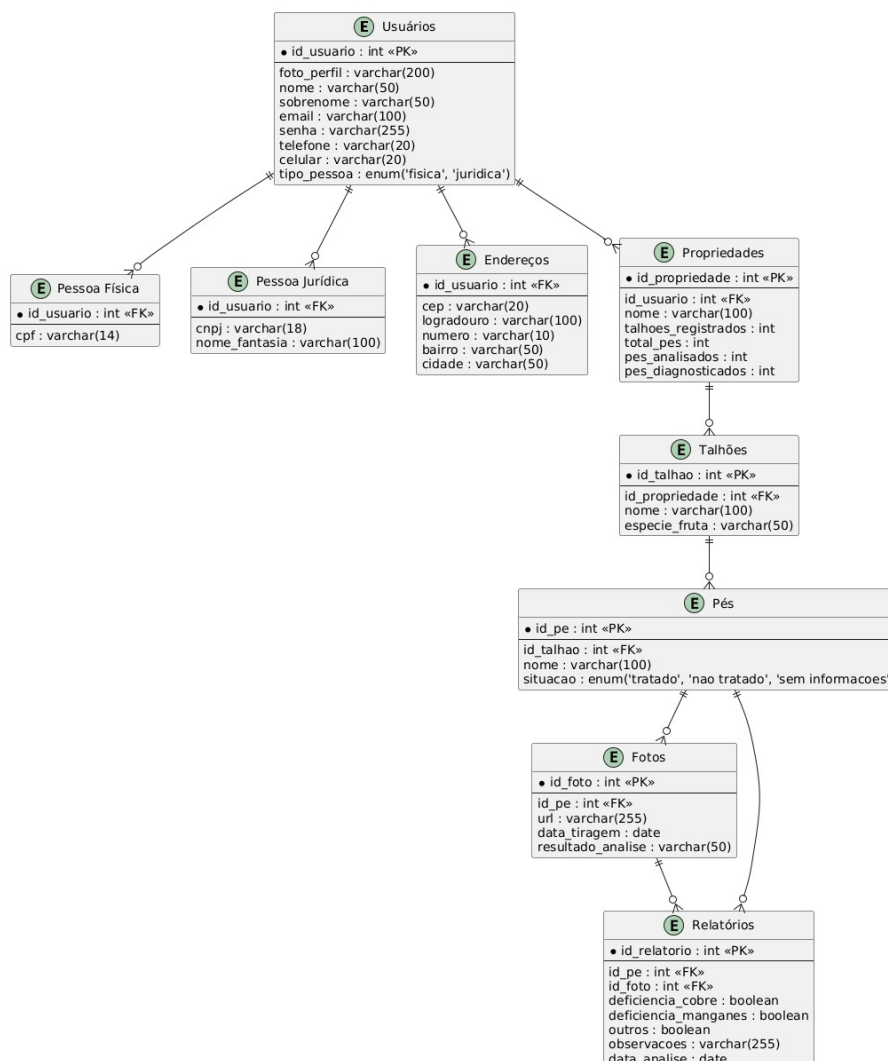
▪ **Tabela relatorios:** Armazena relatórios de diagnóstico para cada pé.

- id_relatorio: Chave primária do tipo int, com auto_increment.
- id_pe: Chave estrangeira que referencia o pé analisado.
- id_foto: Chave estrangeira que referencia a foto utilizada no relatório.
- deficiencia_cobre: Verifica deficiência de cobre, boolean com valor padrão false.
- deficiencia_manganes: Verifica deficiência de manganês, boolean com valor padrão false.
- outros: Indica se o resultado foi adverso, boolean com valor padrão false.
- nao_analisado: Indica se a planta ainda não foi analisada, boolean com valor padrão true.
- observacoes: Observações adicionais do usuário, varchar.
- data_analise: Data em que a análise foi realizada, date not null.

As chaves estrangeiras id_pe e id_foto referenciam, respectivamente, as tabelas pes e fotos.

DER do Banco de dados

Figura 10 – DER



Fonte: Autoria Própria (2024)

Algoritmo de ordenação

O algoritmo de ordenação escolhido foi o Quick Sort, que foi selecionado por ser altamente adequado para grandes volumes de dados, o que pode ser uma realidade em cenários como o gerenciamento de uma plantação, onde existem muitos pés em um talhão. O Quick Sort é eficiente em termos de desempenho, com uma complexidade média de $O(n \log n)$, o que o torna ideal para lidar com grandes quantidades de informações. Além disso, ele oferece um excelente equilíbrio entre desempenho e simplicidade de implementação, facilitando a sua adoção no código. Outro ponto relevante é que o Quick Sort é um algoritmo in-place, ou seja, ele ordena os dados sem a necessidade de alocar espaço extra significativo para armazenar cópias dos dados, o que o torna mais eficiente em termos de uso de memória. No contexto do código, o Quick Sort foi utilizado para ordenar os registros pela data de criação, priorizando os dados mais recentes (do mais novo para o mais velho), o que é crucial para garantir que as informações mais atuais sejam processadas e apresentadas com maior relevância.

Dentro do Quick Sort, o pivô é um elemento selecionado do array que será usado para dividir os dados em duas partes. O objetivo do pivô é organizar os dados ao seu redor, de forma que todos os

elementos menores que o pivô fiquem à esquerda dele e todos os elementos maiores fiquem à direita. Este processo de divisão e conquista continua de forma recursiva até que o array esteja totalmente ordenado. O pivô, portanto, desempenha um papel fundamental no funcionamento eficiente do algoritmo, garantindo que a ordenação seja realizada de maneira progressiva.

Logo abaixo do pseudocódigo do algoritmo, está a tela Figura 11, que mostra a implementação do algoritmo em prática.

Algorithm 1 Algoritmo QuickSort para ordenar os pés de um talhão pela data

```
1: function QUICKSORT(pes, data_criacao)
2:   if tamanho(pes) ≤ 1 then
3:     return pes
4:   end if
5:   pivô ← pes[tamanho(pes) - 1]
6:   esquerda ← []
7:   direita ← []
8:   dataPivô ← TODATE(pivô.data_criacao)
9:   for i ← 0 até tamanho(pes) - 2 do
10:    dataAtual ← TODATE(pes[i].data_criacao)
11:    if dataAtual > dataPivô then
12:      esquerda.add(pes[i])
13:    else
14:      direita.add(pes[i])
15:    end if
16:  end for
17:  return QUICKSORT(esquerda, data_criacao) + [pivô] + QUICKSORT(direita, data_criacao)
18: end function
```

Caso Base: $\text{QuickSort}(pes) = pes$ se $\text{tamanho}(pes) \leq 1$

Caso Geral:
 $\text{QuickSort}(pes) = \text{QuickSort}(esquerda) + \{\text{pivô}\} + \text{QuickSort}(direita)$

onde:

- esquerda contém os elementos menores que o pivô.
- direita contém os elementos maiores ou iguais ao pivô.
- A recursão é aplicada nas sublistas esquerda e direita.

Figura 11 – Tela histórico de pés



Fonte: Autoria Própria (2024)

Modelo de negócios Canvas

O modelo de negócios Canvas do projeto NitrusLeaf Figura 12 tem como principal objetivo delinear os elementos cruciais para o sucesso do nosso empreendimento. Esse modelo abrange várias áreas essenciais, incluindo nossos parceiros, proposta de valor, relacionamento com o cliente, recursos e atividades chave, canais, estrutura de custos e fontes de renda.

Parceiros Chave

Nosso foco principal em parceiros chave são os locais e entidades envolvidas no setor agrícola, especialmente aqueles interessados em inovação tecnológica. Esses parceiros incluem cooperativas agrícolas, universidades, centros de pesquisa, empresas de tecnologia agrícola, secretarias de agricultura dos municípios do Vale do Ribeira e associações de fazendeiros. A colaboração com esses parceiros é fundamental para ampliar o alcance do projeto e assegurar suporte técnico e científico.

Proposta de Valor

A proposta de valor do NitrusLeaf gira em torno da capacidade de identificar deficiências nutricionais nas plantas, especificamente a falta de manganês e cobre nas folhas de mexerica, de maneira eficiente e em tempo real. Além disso, o projeto visa manter um padrão elevado de qualidade dos frutos, ajudando os agricultores a otimizar a saúde das plantas e a produtividade.

Relacionamento com o Cliente

O relacionamento com o cliente é focado em oferecer um suporte abrangente. Isso inclui suporte técnico para a utilização do aplicativo via WhatsApp e feedback do cliente pelo app, além de canais de comunicação para feedback e resolução de dúvidas. Nosso objetivo é garantir que os clientes se sintam apoiados e possam maximizar os benefícios do nosso sistema.

Recursos Chave

Os recursos chave para o desenvolvimento e operação do NitrusLeaf incluem infraestrutura tecnológica (servidores, drones, câmeras de alta resolução), conhecimento técnico em agronomia e TI, uma equipe de suporte dedicada, programadores, instaladores do sistema físico, funcionários para suporte online e host para hospedar o site. Esses recursos são essenciais para o funcionamento eficaz do sistema.

Atividades Chave

As atividades chave do projeto incluem o desenvolvimento contínuo do software, a calibração dos algoritmos de IA para identificar deficiências nutricionais, a manutenção dos drones e outros equipamentos, e a realização de testes de campo para validar os diagnósticos fornecidos pelo sistema.

Canais

Os canais através dos quais promovemos e oferecemos nossos serviços incluem nosso website, redes sociais, feiras agrícolas, eventos de tecnologia, newsletters, parcerias com distribuidores agrícolas e anúncios pelas secretarias de agricultura dos municípios do Vale do Ribeira.

Estrutura de Custos

A estrutura de custos engloba despesas com desenvolvimento e manutenção do software, compra e manutenção de equipamentos (drones e câmeras), marketing e promoção, salários da equipe, custos operacionais gerais como servidores e infraestrutura de TI, manutenção dos itens que realizam o monitoramento das mexericas, compra dos produtos necessários para o monitoramento, host para hospedar as informações, aluguel do sistema e itens necessários, e mão de obra para instalação e manutenção.

Fontes de Renda

A principal fonte de renda do NitrusLeaf provém da venda de assinaturas para o uso do aplicativo, serviços de análise de solo e plantas, consultoria técnica, parcerias com empresas e aluguel do sistema.

Em resumo, o modelo de negócios Canvas do NitrusLeaf oferece uma visão abrangente de como estruturamos nosso projeto para atingir nossos objetivos e atender às necessidades dos nossos clientes. Nossa abordagem integrada garante que todos os aspectos do negócio estejam alinhados para promover a saúde e produtividade das plantações de nossos usuários.

CONCLUSÃO

Inicialmente, o projeto tem como objetivo buscar uma solução para as deficiências minerais encontradas na mexeriqueira (*Citrus reticulata*), especificamente na variedade conhecida como mexerica, apresentando uma alternativa ao problema por meio do uso de tecnologia. Assim, elaboramos um projeto cuja ideia central é criar uma aplicação capaz de identificar, em tempo real, as deficiências minerais pelas quais a planta está passando. Isso permitirá produzir um diagnóstico preciso, facilitando o processo de recuperação da planta, evitando a perda de frutos e otimizando o tempo dos produtores, suprimindo a necessidade de uma identificação rápida e eficiente diretamente no campo.

Durante a pesquisa, identificamos algumas limitações relacionadas às condições do solo e à abrangência geográfica do estudo, que é restrito a alguns países. A deficiência de minerais nas plantas está diretamente associada à acidez do solo. Nosso estudo tem como objetivo identificar, especificamente, deficiências de manganês e cobre em plantas de *Citrus reticulata* (mexerica) por meio de análise foliar. Pesquisas indicam que uma planta com deficiência de manganês geralmente não apresenta deficiência de cobre, e vice-versa. Análises mais aprofundadas mostram que essas deficiências estão intimamente ligadas ao pH do solo: a carência de manganês tende a ocorrer em solos mais ácidos, enquanto a deficiência de cobre é mais comum em solos alcalinos (Bruna, 2019; Machado, 2022).

Futuramente, o projeto busca desenvolver um aplicativo para dispositivos móveis, como celulares e tablets, que empregará visão computacional, aprendizado profundo (*deep learning*) e redes neurais convolucionais para identificar, de forma rápida e eficiente, a presença de uma das duas deficiências minerais abordadas neste estudo.

REFERÊNCIAS

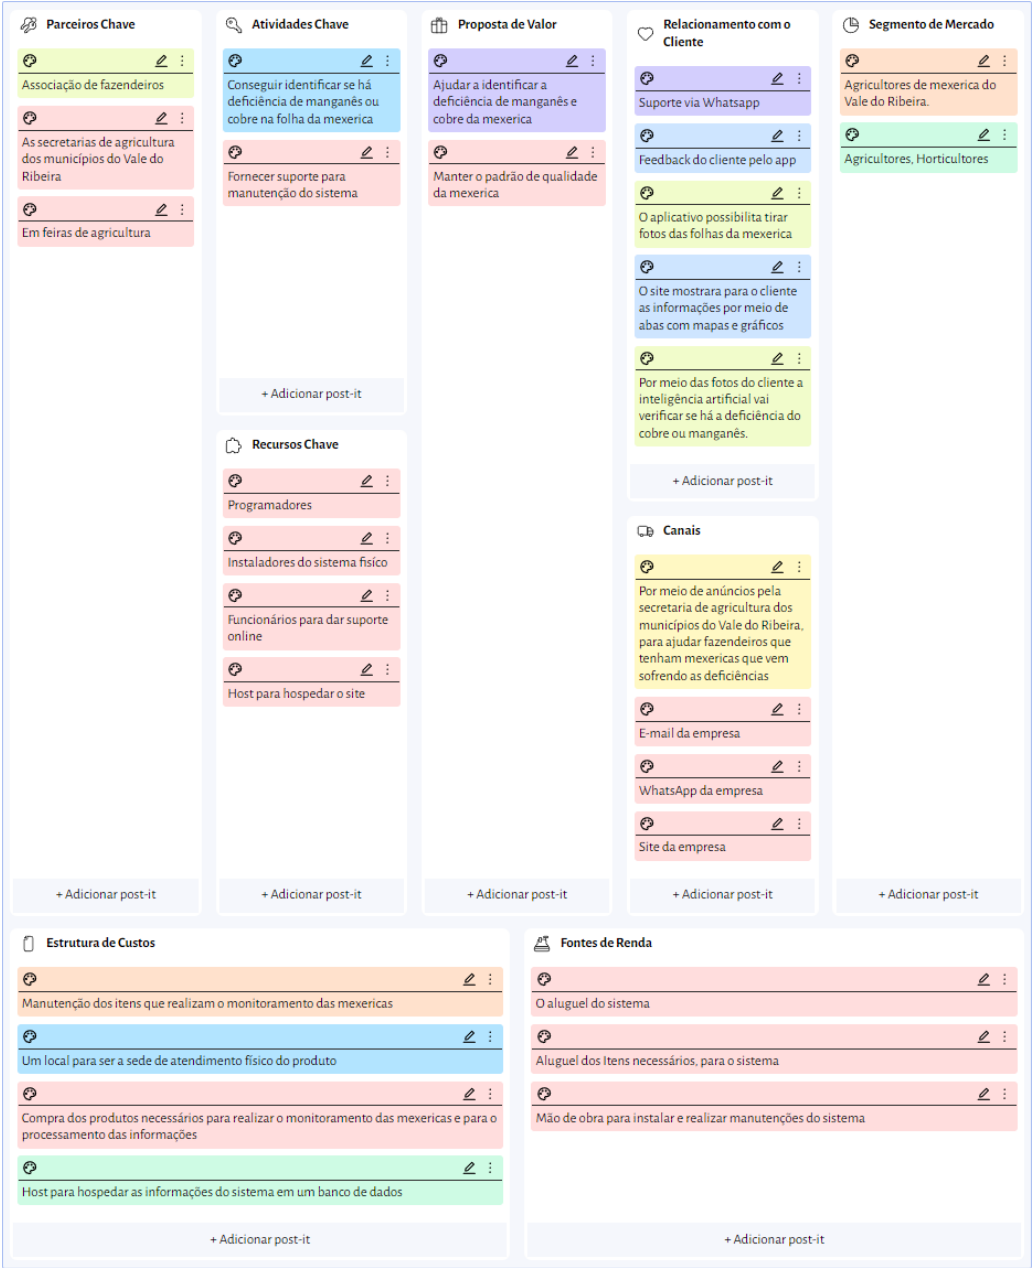
- AEGRO. **O que são mapas NDVI e como utilizá-los na fazenda**. Porto Alegre, RS: [s. n.], 2020. Blog aegro. Disponível em: <<https://blog.aegro.com.br/ndvi/>>. Acesso em: 29 mai. 2024.
- AREGBE, Ikeoluwa; FARNSWORTH, Derek; SIMNITT, Skyler. **Citrus Greening, Hurricanes, and the Decline of the Florida Citrus Industry**. [S. l.: s. n.], 2024. Southern Ag Today. Disponível em: <<https://southernagtoday.org/2024/01/05/citrus-greening-hurricanes-and-the-decline-of-the-florida-citrus-industry/>>. Acesso em: 4 mai. 2024.
- BRUNA, Jackellyne. **9 micronutrientes das plantas: como e quando utilizá-los**. Porto Alegre, RS: [s. n.], 2019. Blog aegro. Disponível em: <<https://blog.aegro.com.br/micronutrientes/#:~:text=Os%20sintomas%20de%20defici%C3%Aancia%20de%20mangan%C3%AAs%20podem%20frequentemente%20ser%20confundidos,do%20solo%20%C3%A9%20t%C3%A3o%20cr%C3%ADtico.&text=O%20pH%20do%20solo%20mais,folhas%20amareladas%20na%20sua%20lavoura.>>>. Acesso em: 30 mai. 2024.
- BUENO, Newton; GASPAROTTO, Luadir. Sintomas de deficiências nutricionais em citros. **Embrapa**, Embrapa Amazônia Ocidental, p. 19, dez. 1999. ISSN 1517-2449. Disponível em: <<https://ainfo.cnptia.embrapa.br/digital/bitstream/item/64450/1/CircTec-06-1999.pdf>>. Acesso em: 19 abr. 2024.
- CHRISTIN, Sylvain; HERVET, Éric; LECOMTE, Nicolas. Applications for deep learning in ecology. **Methods in Ecology and Evolution**, British Ecological Society(BES), p. 1632–1644, out. 2019. DOI: 10.1111/2041-210X.13256. Acesso em: 5 mai. 2024.
- FUNDECITRUS. **Greening**. Araraquara, SP: [s. n.], 2018. Fundecitrus, ciência e sustentabilidade para a citrucultura. Disponível em: <<https://www.fundecitrus.com.br/doencas/greening>>. Acesso em: 26 abr. 2024.
- GHORAI, Ankit Kumar *et al.* Image Processing Based Detection of Diseases and Nutrient Deficiencies in Plants. **SATSA Mukhapatra - Annual Technical Issue**, v. 25, p. 1–25, 2021. ISSN 0971-975X. Disponível em: <https://www.researchgate.net/publication/349707825_Image_Processing_Based_Detection_of_Diseases_and_Nutrient_Deficiencies_in_Plants>. Acesso em: 31 out. 2024.
- MACHADO, Anderson Wolf. **Cobre - tudo o que você precisa saber sobre este adubo**. [S. l.: s. n.], 2022. Agrolink. Disponível em: <https://www.agrolink.com.br/fertilizantes/nutrientes/cobre---tudo-o-que-voce-precisa-saber-sobre-este-adubo_468470.html>. Acesso em: 30 mai. 2024.
- MUTHUSAMY, Sudhakar; RAMU, Swarna Priya. Computer Vision Based Machine Learning and Deep Learning Approaches for Identification of Nutrient Deficiency in Crops: A Survey. **Nature Environment and Pollution Technology**, v. 22, n. 3, p. 1387–1399, 2023. ISSN 2395-3454. DOI: <https://doi.org/10.46488/NEPT.2023.v22i03.025>.
- QIN, Zhuwei *et al.* How convolutional neural networks see the world — A survey of convolutional neural network visualization methods. **Mathematical Foundations of Computing**, American Institute of Mathematical Sciences, v. 1, n. 2, p. 149–180, mai. 2018. DOI: 10.3934/mfc.2018008.

TRAN, Trung-Tin *et al.* A Comparative Study of Deep CNN in Forecasting and Classifying the Macronutrient Deficiencies on Development of Tomato Plant. **Applied Sciences**, v. 9, n. 8, 2019. DOI: <https://doi.org/10.3390/app9081601>.

TRINDADE, José Pedro Pereira; VOLK, Leandro Bochi da Silva; ROCHA, Danilo Serra da. Avaliação do índice normalizado de vegetação no monitoramento de sistema de unidades de manejo. **Bagé**, Embrapa Pecuária Sul, p. 31, mai. 2021. ISSN 1983-0467. Disponível em: <<https://ainfo.cnptia.embrapa.br/digital/bitstream/item/223511/1/BPD-47-online.pdf>>. Acesso em: 29 mai. 2024.

APÊNDICE A — MODELO DE NEGÓCIOS CANVAS

Figura 12 – Modelo de negócios Canvas



Fonte: Autoria Própria (2024)